

Introducción al curso

Estadística para Datos Multivariantes

Francisco Moreira Villegas

June 3, 2026



¿De qué trata este curso?

- ▶ Analizar datos con **múltiples variables observadas simultáneamente**.
- ▶ Identificar **estructura, patrones, grupos y relaciones**.
- ▶ Usar métodos estadísticos con apoyo computacional en **R**.

No analizaremos variables aisladas.
Analizaremos sistemas de variables.

Preguntas que responde el análisis multivariante

- ▶ ¿Qué variables explican mayor variabilidad?
- ▶ ¿Existen grupos naturales en los datos?
- ▶ ¿Qué individuos son similares entre sí?
- ▶ ¿Podemos reducir muchas variables a pocas dimensiones?
- ▶ ¿Podemos clasificar nuevas observaciones?

Ejemplos de aplicación

- ▶ Educación
- ▶ Salud
- ▶ Marketing
- ▶ Finanzas
- ▶ Deportes
- ▶ Industria
- ▶ Calidad
- ▶ Investigación científica

La clave no es tener muchas variables, sino entender su relación conjunta.

Estructura básica

- Una base multivariante se representa como una matriz:

$$\mathbf{X}_{n \times p} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

- n : individuos, casos u observaciones.
- p : variables medidas en cada individuo.

Ingreso a R en la nube

- ▶ Usaremos **Posit Cloud** para trabajar con R sin instalar software localmente.
- ▶ Pasos de acceso:
 1. Ingresar a: <https://posit.cloud>
 2. Crear una cuenta o iniciar sesión.
 3. Crear un nuevo proyecto: **New Project**.
 4. Seleccionar: **New RStudio Project**.
 5. Abrir un script nuevo: **File** → **New File** → **R Script**.

Trabajaremos en la nube para asegurar un entorno común durante el curso.

Primer contacto en R

```
data(iris)

dim(iris)
head(iris)
summary(iris)
```

- ▶ iris tiene variables cuantitativas y una variable de grupo.
- ▶ Es útil para introducir visualización, reducción de dimensión y clasificación.

¿Qué hace multivariante a un problema?

Univariante

- ▶ Una variable respuesta.
- ▶ Análisis separado.
- ▶ Menor complejidad.

Multivariante

- ▶ Varias variables simultáneas.
- ▶ Dependencia entre variables.
- ▶ Estructura conjunta.

El objetivo es estudiar la información conjunta, no variable por variable.

Covarianza y correlación

- ▶ La **covarianza** mide variación conjunta.
- ▶ La **correlación** estandariza esa relación.
- ▶ En análisis multivariante, la matriz de correlación suele ser el punto de partida.

$$\mathbf{R} = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

Matriz de correlaciones en R

```
X <- iris[, 1:4]  
  
R <- cor(X)  
round(R, 2)
```

- ▶ Permite detectar variables redundantes.
- ▶ Ayuda a decidir si tiene sentido reducir dimensión.

Visualización rápida

```
pairs(X,  
      col = iris$Species,  
      pch = 19)
```

- ▶ Explora relaciones bivariadas.
- ▶ Permite observar separación entre grupos.
- ▶ No reemplaza al análisis formal.

¿Por qué escalar los datos?

- ▶ Variables con unidades distintas pueden dominar el análisis.
- ▶ PCA, clustering y distancias son sensibles a la escala.
- ▶ Una transformación frecuente es:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

Escalar no es un detalle técnico: puede cambiar las conclusiones.

Escalamiento en R

```
X_scaled <- scale(X)

apply(X_scaled, 2, mean)
apply(X_scaled, 2, sd)
```

- ▶ Cada variable queda con media cercana a 0.
- ▶ Cada variable queda con desviación estándar igual a 1.

Idea central del PCA

- ▶ PCA transforma variables correlacionadas en componentes no correlacionadas.
- ▶ Las primeras componentes concentran la mayor variabilidad.
- ▶ Es una técnica exploratoria, no un modelo causal.

Muchas variables $\longrightarrow$ pocas dimensiones informativas

PCA en R

```
pca <- prcomp(X, scale. = TRUE)

summary(pca)
pca$rotation
```

- ▶ `summary(pca)` muestra varianza explicada.
- ▶ `rotation` muestra los pesos de cada variable.

Visualización del PCA

```
plot(pca$x[,1], pca$x[,2],  
     col = iris$Species,  
     pch = 19,  
     xlab = "PC1",  
     ylab = "PC2")
```

- ▶ Permite observar los datos en dos dimensiones.
- ▶ Facilita interpretar separación entre observaciones.

Idea central del clustering

- ▶ Busca grupos de observaciones similares.
- ▶ No requiere conocer previamente las clases.
- ▶ Depende de la distancia, escala y método utilizado.

Clustering no descubre “la verdad”: propone una estructura posible.

K-means en R

```
set.seed(123)

km <- kmeans(X_scaled, centers = 3)

table(km$cluster, iris$Species)
```

- ▶ Compara grupos encontrados con especies reales.
- ▶ Sirve como ejemplo inicial de segmentación.

Unidades principales del curso

Unidad	Tema central
1	Metodologías basadas en estructuras latentes
2	Regresión lineal
3	Modelos de clasificación
4	Modelos de conteos

De la exploración multivariante al modelado predictivo e inferencial.

Lo que no haremos en esta introducción

- ▶ Repasar probabilidad elemental.
- ▶ Deducir distribuciones univariantes.
- ▶ Revisar estadística descriptiva básica en detalle.
- ▶ Saturar con fórmulas sin interpretación.

El foco será el razonamiento multivariante aplicado.

¿Por qué necesitamos inferencia?

- ▶ En la práctica, casi nunca observamos toda la población.
- ▶ Trabajamos con una **muestra** y usamos sus resultados para decir algo sobre una **población**.
- ▶ La inferencia permite cuantificar la incertidumbre asociada a esas conclusiones.

Muestra $\longrightarrow$ **Estimación** $\longrightarrow$ **Conclusión sobre la población**

En análisis multivariante, muchas decisiones se basan en relaciones estimadas entre variables.

Parámetros, estimadores e hipótesis

- ▶ Un **parámetro** describe una característica poblacional.

$$\mu, \quad \sigma^2, \quad \rho$$

- ▶ Un **estimador** se calcula con los datos muestrales.

$$\bar{x}, \quad s^2, \quad r$$

- ▶ Una **hipótesis estadística** es una afirmación sobre un parámetro.

H_0 : hipótesis nula H_1 : hipótesis alternativa

La inferencia compara lo observado en la muestra con lo esperado bajo H_0 .

Contraste de hipótesis para correlaciones

- ▶ En la muestra observamos una correlación r .
- ▶ Pero el interés real suele estar en la correlación poblacional ρ .
- ▶ Una pregunta inferencial típica es:

$$H_0 : \rho = 0 \quad \text{vs.} \quad H_1 : \rho \neq 0$$

- ▶ Si rechazamos H_0 , concluimos que existe evidencia estadística de asociación lineal.
- ▶ Si no rechazamos H_0 , la muestra no aporta evidencia suficiente de correlación lineal.

Una correlación muestral no siempre implica una correlación poblacional significativa.

Contraste de correlación en R

```
data(iris)

x <- iris$Sepal.Length
y <- iris$Petal.Length

cor(x, y)

cor.test(x, y)
```

- ▶ `cor(x, y)` calcula la correlación muestral.
- ▶ `cor.test(x, y)` realiza el contraste de hipótesis.
- ▶ El valor-p permite evaluar la evidencia contra $H_0 : \rho = 0$.

Mensaje clave

- ▶ La estadística descriptiva resume lo observado en la muestra.
- ▶ La inferencia estadística permite generalizar con incertidumbre.
- ▶ En correlaciones, distinguiremos entre:

r = correlación muestral ρ = correlación poblacional

No basta con calcular r : necesitamos evaluar si la relación es estadísticamente significativa.

Cierre de la clase

- ▶ Los datos multivariantes requieren analizar relaciones conjuntas.
- ▶ La escala, la correlación y la distancia importan.
- ▶ PCA y clustering serán métodos centrales del curso.
- ▶ R será usado como herramienta de análisis e interpretación.

La estadística multivariante conecta datos complejos con decisiones informadas.