

Metodologías basadas en estructuras latentes

Estadística para Datos Multivariantes

Francisco Moreira Villegas

June 6, 2026

Unidad 1: Estructuras latentes

- ▶ Análisis de correlaciones
- ▶ Análisis de componentes principales
- ▶ Correlación canónica

El objetivo es descubrir relaciones no observadas directamente a partir de variables medidas.

¿Qué es una estructura latente?

- ▶ Es una dimensión no observada directamente.
- ▶ Se manifiesta a través de variables observadas.
- ▶ Aparece cuando varias variables se mueven de forma conjunta.

Variables observadas $\longrightarrow$ estructura subyacente

Análisis de correlaciones: idea central

- ▶ La correlación cuantifica la **fuerza** y la **dirección** de una relación lineal entre dos variables cuantitativas.
- ▶ Es una herramienta inicial para detectar patrones de asociación en datos multivariantes.
- ▶ En esta unidad nos interesa pasar de correlaciones individuales a una **matriz de correlaciones**.

$$-1 \leq r_{xy} \leq 1$$

La correlación es una primera aproximación a la estructura conjunta de los datos.

Relaciones fuertes y débiles

Relación fuerte

- ▶ Los puntos se agrupan cerca de una línea.
- ▶ Hay baja dispersión alrededor de la tendencia.
- ▶ El patrón lineal es más predecible.

Relación débil

- ▶ Los puntos están más dispersos.
- ▶ Existe mayor variabilidad individual.
- ▶ La predicción lineal es menos precisa.

La magnitud de r aumenta cuando los datos se alinean mejor alrededor de una tendencia lineal.

La escala de la correlación

- El coeficiente de Pearson se interpreta en una escala entre -1 y 1 .

$$r = 1$$

Relación lineal
positiva perfecta.

$$r = 0$$

Ausencia de patrón
lineal detectable.

$$r = -1$$

Relación lineal
negativa perfecta.

El signo indica dirección; el valor absoluto indica fuerza lineal.

Fuerza del coeficiente r

Valor absoluto de r	Interpretación orientativa
$ r \approx 1.00$	Relación lineal casi perfecta
$ r \approx 0.80$	Relación lineal fuerte
$ r \approx 0.50$	Relación lineal moderada
$ r \approx 0.20$	Relación lineal débil
$ r \approx 0.00$	Sin relación lineal apreciable

La interpretación de la fuerza depende del contexto, del tamaño muestral y del área de aplicación.

Correlación no implica causalidad

- ▶ Dos variables pueden variar conjuntamente sin que una cause directamente a la otra.
- ▶ Puede existir una **variable de confusión** que explique ambas tendencias.
- ▶ También pueden aparecer correlaciones espurias o asociaciones sin sentido causal.

Asociación estadística $\neq$ relación causal

La correlación describe co-movimiento; la causalidad requiere diseño, teoría y evidencia adicional.

Fórmula de la correlación de Pearson

- ▶ La correlación de Pearson estandariza la covarianza entre dos variables.

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

- ▶ El numerador mide variación conjunta.
- ▶ El denominador ajusta por la dispersión de cada variable.

Pearson mide asociación lineal en una escala comparable entre diferentes pares de variables.

Proceso de cálculo

1. Calcular las medias:

$$\bar{x}, \quad \bar{y}$$

2. Medir desviaciones respecto a la media:

$$x_i - \bar{x}, \quad y_i - \bar{y}$$

3. Calcular la variación conjunta:

$$(x_i - \bar{x})(y_i - \bar{y})$$

4. Estandarizar por la dispersión de ambas variables.

La correlación compara cuánto varían juntas dos variables respecto a su variabilidad individual.

Correlación y R^2

- ▶ En regresión lineal simple, el coeficiente de determinación es:

$$R^2 = r^2$$

Correlación r

- ▶ Mide dirección y fuerza.
- ▶ Puede ser positiva o negativa.
- ▶ Toma valores entre -1 y 1 .

Coeficiente R^2

- ▶ Mide proporción de variabilidad explicada.
- ▶ Siempre es no negativo.
- ▶ Toma valores entre 0 y 1 .

r conserva la dirección; R^2 expresa capacidad explicativa en términos de variación.

La necesidad del valor-p

- ▶ Una muestra puede mostrar correlación aun cuando en la población no exista asociación lineal.
- ▶ El valor-p cuantifica qué tan compatible es el resultado observado con la hipótesis nula.
- ▶ En el contraste usual:

$$H_0 : \rho = 0 \quad \text{vs.} \quad H_1 : \rho \neq 0$$

El valor-p ayuda a distinguir una asociación muestral de una evidencia estadística poblacional.

Contraste para correlaciones

- ▶ En la muestra observamos una correlación r .
- ▶ El interés real es evaluar la correlación poblacional ρ .

$$H_0 : \rho = 0 \quad \text{vs.} \quad H_1 : \rho \neq 0$$

- ▶ Bajo H_0 , el estadístico de prueba es:

$$t = \frac{r}{\sqrt{\frac{1-r^2}{n-2}}} \sim t_{n-2}$$

- ▶ r : correlación muestral.
- ▶ n : tamaño de muestra.
- ▶ $n - 2$: grados de libertad.

No basta con calcular r : debemos evaluar si la correlación es estadísticamente significativa.

Correlaciones en R

```
data(iris)

X <- iris[, 1:4]

R <- cor(X)

round(R, 2)
```

- ▶ `cor()` calcula la matriz de correlaciones.
- ▶ Por defecto usa correlación de Pearson.
- ▶ La matriz resume asociaciones lineales por pares.

Contraste de correlación en R

```
x <- iris$Sepal.Length  
y <- iris$Petal.Length  
  
cor(x, y)  
  
cor.test(x, y)
```

- ▶ `cor()` entrega la correlación muestral.
- ▶ `cor.test()` realiza el contraste para ρ .
- ▶ El valor-p se interpreta frente al nivel de significancia.

Limitaciones del coeficiente de Pearson

- ▶ Solo mide asociación **lineal**.
- ▶ Es sensible a valores atípicos.
- ▶ No captura adecuadamente relaciones curvas o no monótonas.
- ▶ No establece causalidad.

Antes de interpretar una correlación, siempre conviene visualizar los datos.

Actividad práctica: análisis de correlaciones

- ▶ Formen grupos y seleccionen un conjunto de datos:
 - ▶ un dataset propio, o
 - ▶ el dataset Credit del paquete trabajado en clase.
- ▶ Realicen un análisis de correlaciones entre las variables cuantitativas que consideren relevantes.
- ▶ Elaboren un gráfico adecuado para comunicar la estructura de asociación.
- ▶ Presenten conclusiones breves sobre los patrones encontrados.

Tiempo de trabajo: 10 minutos
Socialización: 5 minutos por grupo

Objetivo: pasar del cálculo de correlaciones a la interpretación estadística.

Análisis de Componentes Principales

- ▶ El PCA es una técnica de reducción de dimensión.
- ▶ Transforma variables originales correlacionadas en nuevas variables llamadas **componentes principales**.
- ▶ Las primeras componentes concentran la mayor parte de la variabilidad de los datos.

Muchas variables $\longrightarrow$ pocas dimensiones
informativas

PCA permite simplificar datos multivariantes sin perder la estructura esencial.

PCA como estructura latente

- ▶ Las componentes principales no se observan directamente.
- ▶ Se construyen como combinaciones lineales de las variables originales.
- ▶ Cada componente puede interpretarse como una dimensión latente de variabilidad.

$$Z_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p$$

La estructura latente aparece cuando varias variables se mueven conjuntamente.

Algoritmo general del PCA

1. Organizar los datos en una matriz $\mathbf{X}_{n \times p}$.
2. Centrar o estandarizar las variables.
3. Calcular la matriz de covarianzas o correlaciones.
4. Obtener autovalores y autovectores.
5. Proyectar los datos sobre las nuevas componentes.

El PCA combina geometría, álgebra lineal e interpretación estadística.

Paso 1: matriz de datos

- Partimos de una matriz de datos:

$$\mathbf{X}_{n \times p} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

- n : observaciones o individuos.
- p : variables medidas en cada observación.

Cada observación es un punto en un espacio de p dimensiones.

Paso 2: centrado de los datos

- ▶ PCA requiere trasladar el centro de los datos al origen.
- ▶ Para cada variable se resta su media:

$$x_{ij}^c = x_{ij} - \bar{x}_j$$

- ▶ Si las variables están en diferentes escalas, se recomienda estandarizar:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

Centrar cambia el origen, pero conserva la forma relativa de la nube de puntos.

Paso 3: matriz de covarianza

- ▶ PCA analiza cómo varían conjuntamente las variables.
- ▶ Para dos variables X y Y , la covarianza muestral es:

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- ▶ En varias dimensiones se construye la matriz:

$$\mathbf{S} = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{pmatrix}$$

La matriz de covarianza resume la estructura de variabilidad conjunta.

Paso 4: autovalores y varianza explicada

- ▶ Los autovalores indican cuánta varianza captura cada componente.
- ▶ Se obtienen resolviendo:

$$\det(\mathbf{S} - \lambda \mathbf{I}) = 0$$

- ▶ El mayor autovalor corresponde a la primera componente principal.
- ▶ La proporción de varianza explicada por la componente i es:

$$\frac{\lambda_i}{\lambda_1 + \lambda_2 + \cdots + \lambda_p}$$

Las primeras componentes son las que capturan mayor variabilidad.

Paso 5: autovectores y loadings

- ▶ Los autovectores definen la dirección de cada componente.
- ▶ Para cada autovalor λ_i , se resuelve:

$$(\mathbf{S} - \lambda_i \mathbf{I})\mathbf{v}_i = 0$$

- ▶ Cada autovector se normaliza para tener longitud uno:

$$\hat{\mathbf{v}}_i = \frac{\mathbf{v}_i}{\|\mathbf{v}_i\|}$$

- ▶ Sus elementos se interpretan como **loadings** o pesos de las variables originales.

Los loadings permiten interpretar qué variables construyen cada componente.

Paso 6: proyección y ortogonalidad

- ▶ Una vez definidas las direcciones principales, los datos se proyectan sobre ellas.
- ▶ La primera componente es la dirección de máxima varianza.
- ▶ Las siguientes componentes son ortogonales entre sí.

$$PC_1 = \mathbf{X}\hat{\mathbf{v}}_1 \quad PC_2 = \mathbf{X}\hat{\mathbf{v}}_2$$

$$PC_1 \perp PC_2$$

La ortogonalidad evita redundancia entre componentes.

¿Por qué usar PCA?

- ▶ Reducir dimensión.
- ▶ Visualizar datos multivariantes.
- ▶ Identificar patrones, grupos o valores atípicos.
- ▶ Construir variables sintéticas no correlacionadas.
- ▶ Eliminar redundancia entre variables correlacionadas.

PCA es especialmente útil cuando muchas variables contienen información repetida.

PCA en R: código base con iris

```
data(iris)

X <- iris[, 1:4]

pca <- prcomp(X, scale. = TRUE)

summary(pca)

pca$rotation

head(pca$x)
```

Usamos `scale. = TRUE` porque las variables pueden tener escalas y variabilidades distintas.

Varianza explicada en R

```
var_exp <- pca$sdev^2 / sum(pca$sdev^2)

round(var_exp, 3)

cumsum(var_exp)
```

- ▶ `var_exp`: proporción de varianza explicada por cada componente.
- ▶ `cumsum(var_exp)`: varianza explicada acumulada.

La varianza acumulada permite decidir cuántas componentes conservar.

Scree plot en R

```
plot(var_exp,  
      type = "b",  
      pch = 19,  
      xlab = "Componente principal",  
      ylab = "Proporcion de varianza explicada",  
      col = "steelblue")
```

- ▶ El scree plot muestra la importancia relativa de cada componente.
- ▶ Se busca identificar una caída marcada o “codo” en la curva.

En *iris*, las primeras componentes concentran gran parte de la variabilidad.

Visualización PC1 vs PC2

```
plot(pca$x[,1], pca$x[,2],  
     pch = 19,  
     col = iris$Species,  
     xlab = "PC1",  
     ylab = "PC2")  
  
legend("topright",  
       legend = levels(iris$Species),  
       col = 1:3,  
       pch = 19)
```

- ▶ Cada punto representa una flor.
- ▶ El color identifica la especie.
- ▶ La separación sugiere estructura multivariante entre especies.

Preguntas para interpretar el PCA con iris

- ▶ ¿Qué porcentaje de variabilidad explican PC1 y PC2?
- ▶ ¿Qué variables tienen mayor peso en PC1?
- ▶ ¿Qué variables tienen mayor peso en PC2?
- ▶ ¿Qué especies se separan mejor en el plano PC1 vs PC2?
- ▶ ¿Qué interpretación puede darse a las componentes?

El PCA permite explorar si las variables morfológicas resumen diferencias entre especies.

Mensaje clave sobre PCA

- ▶ PCA identifica direcciones de máxima variabilidad.
- ▶ Las componentes son combinaciones lineales de las variables originales.
- ▶ Los autovalores explican cuánta información conserva cada componente.
- ▶ Los loadings permiten interpretar el significado de las componentes.
- ▶ La visualización facilita detectar patrones, grupos y observaciones atípicas.

PCA convierte complejidad multivariante en dimensiones interpretables.

Actividad práctica: PCA

- ▶ Utilicen el dataset `USArrests`, disponible directamente en R.
- ▶ Realicen un análisis de componentes principales usando las variables cuantitativas del dataset.
- ▶ Interpreten:
 - ▶ cuánta variabilidad explican las dos primeras componentes;
 - ▶ qué variables pesan más en cada componente;
 - ▶ qué patrones se observan en el gráfico PC1 vs. PC2.
- ▶ Elaboren conclusiones sobre la estructura latente de los datos.

Tiempo de trabajo: 15 minutos
Socialización: 5 minutos por grupo

Objetivo: pasar de muchas variables correlacionadas a pocas dimensiones interpretables.

Preguntas para interpretar el PCA

- ▶ ¿Qué porcentaje de variabilidad explican PC1 y PC2?
- ▶ ¿Qué variables tienen mayor peso en PC1?
- ▶ ¿Qué variables tienen mayor peso en PC2?
- ▶ ¿Qué estados aparecen más alejados del centro?
- ▶ ¿Qué interpretación podría darse a cada componente?

Un PCA no termina en el cálculo: termina en una interpretación sustantiva.

Correlación canónica

- ▶ Estudia la relación entre dos conjuntos de variables.
- ▶ Busca combinaciones lineales que maximicen la correlación entre ambos grupos.

$$U = a_1X_1 + \cdots + a_pX_p$$

$$V = b_1Y_1 + \cdots + b_qY_q$$

La correlación canónica generaliza la correlación simple a dos bloques multivariantes.

Correlación canónica en R

```
X1 <- iris[, c("Sepal.Length", "Sepal.Width")]  
X2 <- iris[, c("Petal.Length", "Petal.Width")]  
  
cc <- cancel(X1, X2)  
  
cc$cor
```

- ▶ `cancel()` estima las correlaciones canónicas.
- ▶ Permite estudiar asociación entre dos grupos de variables.

Fuentes de referencia

- ▶ James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R*. 2nd ed. Springer.
- ▶ Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- ▶ Izenman, A. J. (2009). *Modern Multivariate Statistical Techniques*. Springer.
- ▶ Rencher, A. C. y Christensen, W. F. (2012). *Methods of Multivariate Analysis*. Wiley.