

Regresión Lineal

Estadística para Datos Multivariantes

Francisco Moreira Villegas

7 de junio de 2026

Unidad 2: Regresión lineal

- ▶ Regresión lineal simple y múltiple
- ▶ Diagnóstico del modelo
- ▶ Heterocedasticidad
- ▶ Autocorrelación

El objetivo es modelar una variable respuesta continua a partir de uno o más predictores.

Modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- ▶ Y_i : variable respuesta.
- ▶ X_i : variable explicativa.
- ▶ β_0 : intercepto.
- ▶ β_1 : cambio esperado en Y por unidad adicional de X .
- ▶ ε_i : error aleatorio.

La regresión busca estimar una relación promedio entre variables.

Ejemplo en R: dataset Auto

```
library(ISLR2)

data(Auto)

modelo_simple <- lm(mpg ~ horsepower, data = Auto)

summary(modelo_simple)
```

- ▶ mpg: rendimiento del automóvil.
- ▶ horsepower: potencia del motor.
- ▶ Se evalúa si la potencia explica el consumo.

Visualización del modelo simple

```
plot(Auto$horsepower, Auto$mpg,  
     pch = 19,  
     col = "steelblue",  
     xlab = "Horsepower",  
     ylab = "MPG")  
  
abline(modelo_simple,  
       col = "red",  
       lwd = 2)
```

La línea representa el valor promedio estimado de mpg para cada nivel de potencia.

Regresión lineal múltiple

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \varepsilon_i$$

- ▶ Permite incorporar varios predictores simultáneamente.
- ▶ Cada coeficiente se interpreta manteniendo constantes los demás predictores.
- ▶ Es útil cuando la respuesta depende de varios factores.

La interpretación cambia: ahora cada efecto es ajustado por las demás variables.

Ejemplo en R: regresión múltiple

```
modelo_multiple <- lm(mpg ~ horsepower + weight + acceleration,  
                      data = Auto)  
  
summary(modelo_multiple)
```

- ▶ Se modela mpg usando potencia, peso y aceleración.
- ▶ El objetivo es explicar mejor la variabilidad del rendimiento.

Supuestos principales del modelo lineal

- ▶ Linealidad entre predictores y respuesta.
- ▶ Independencia de los errores.
- ▶ Varianza constante de los errores.
- ▶ Normalidad aproximada de los errores para inferencia.
- ▶ Ausencia de colinealidad severa.

El diagnóstico del modelo es tan importante como la estimación.

Diagnóstico gráfico en R

```
par(mfrow = c(2, 2))  
  
plot(modelo_multiple)  
  
par(mfrow = c(1, 1))
```

- ▶ Residuales vs ajustados: linealidad y varianza constante.
- ▶ QQ-plot: normalidad aproximada.
- ▶ Scale-Location: heterocedasticidad.
- ▶ Residuales vs leverage: observaciones influyentes.

Heterocedasticidad

- ▶ Ocurre cuando la varianza de los errores no es constante.
- ▶ Puede afectar errores estándar, intervalos de confianza y pruebas de hipótesis.
- ▶ Suele observarse como un patrón de embudo en los residuales.

$$Var(\varepsilon_i) \neq \sigma^2$$

El problema no siempre está en los coeficientes, sino en la inferencia sobre ellos.

Prueba de heterocedasticidad

```
install.packages("lmtest")  
library(lmtest)  
  
bptest(modelo_multiple)
```

- ▶ La prueba de Breusch-Pagan evalúa varianza constante.
- ▶ Hipótesis nula: homocedasticidad.
- ▶ Un valor-p pequeño sugiere heterocedasticidad.

Corrección: errores robustos

```
install.packages("sandwich")  
library(sandwich)  
library(lmtest)  
  
coeftest(modelo_multiple,  
         vcov = vcovHC(modelo_multiple,  
                       type = "HC1"))
```

Los errores estándar robustos permiten hacer inferencia más confiable ante heterocedasticidad.

Autocorrelación

- ▶ Ocurre cuando los errores del modelo están correlacionados entre sí.
- ▶ Es frecuente en datos temporales o secuenciales.
- ▶ Viola el supuesto de independencia de los errores.

$$Cov(\varepsilon_i, \varepsilon_j) \neq 0 \quad i \neq j$$

La autocorrelación puede producir inferencia engañosa si se ignora.

Evaluación de autocorrelación

```
library(lmtest)  
  
dwtest(modelo_multiple)
```

- ▶ La prueba de Durbin-Watson evalúa autocorrelación de primer orden.
- ▶ Hipótesis nula: no autocorrelación.
- ▶ Es especialmente útil en modelos con datos ordenados en el tiempo.

Ejemplo con dataset Credit

```
data(Credit)

modelo_credit <- lm(Balance ~ Income + Limit + Rating + Age,
                    data = Credit)

summary(modelo_credit)

par(mfrow = c(2, 2))
plot(modelo_credit)
par(mfrow = c(1, 1))
```

- Balance: saldo de tarjeta.
- Predictores: ingreso, límite, rating y edad.


Ejemplo: Pruebas de esfuerzo cardiopulmonar

- ▶ Considere el estudio sobre pruebas de esfuerzo cardiopulmonar en pacientes con insuficiencia cardíaca realizado en InCor en la Facultad de Medicina de la USP.
- ▶ Uno de los objetivos del estudio es comparar los grupos formados por las diferentes etiologías cardíacas en cuanto a las respuestas respiratorias y metabólicas obtenidas en la prueba de esfuerzo cardiopulmonar.
- ▶ Otro objetivo del estudio es saber si alguna de las características observadas (o combinación de ellas) puede ser utilizada como factor de pronóstico de óbito.
- ▶ Los datos pueden ser encontrados en `Etiologias-cardiacas.txt`

Ejemplo: Pruebas de esfuerzo cardiopulmonar


- ▶ Etiologías:
 - ▶ CH: Chagásicos (afectados por la enfermedad de Chagas).
 - ▶ ID: Idiopáticos (enfermedades de causa desconocida).
 - ▶ IS: Isquémicos (enfermedades causadas por la falta de flujo sanguíneo adecuado).
 - ▶ C: Control.
- ▶ Considere que el objetivo es explicar la variación del consumo de oxígeno en el umbral anaeróbico ($ml/(kg \cdot min)$) en función de la carga utilizada en la caminadora ergométrica para pacientes con diferentes etiologías (causas) de insuficiencia cardíaca.
- ▶ El **umbral anaeróbico** es un punto (límite) que divide el metabolismo esencialmente aeróbico del metabolismo esencialmente anaeróbico.
- ▶ ¿Cómo responder la pregunta de interés?

Ejemplo: Pruebas de esfuerzo cardiopulmonar



- ▶ ¿Existe una relación entre las dos variables?
- ▶ ¿Qué significa decir que para un valor dado de la carga, el comportamiento del consumo de oxígeno es aleatorio y puede ser modelado “apropiadamente” por una estructura probabilística?

Ejemplo: Pruebas de esfuerzo cardiopulmonar



- ¿Es importante considerar las diferentes etiologías?
- ¿Existe interés en comparar la influencia de la carga en el consumo de oxígeno entre las diferentes etiologías cardíacas?

Regresión Lineal Simple

- ▶ Para el ejemplo anterior, podemos considerar algún tipo de modelo estadístico que nos permita responder las preguntas de interés.
- ▶ Consideraremos modelos lineales, normales y homocedásticos (varianza constante).
- ▶ Un modelo de regresión lineal simple, normal, homocedástico es dado por:

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n,$$

en que

- ▶ x_i es la variable independiente, predictora o covariable.
- ▶ Y_i es la variable dependiente o de respuesta.
- ▶ β_0 y β_1 son los coeficientes de regresión (a estimar).
- ▶ $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$ es el término de error (factores diferentes de x que afectan Y).

Regresión Lineal Simple


- ▶ Supuestos del modelo de regresión lineal:
 - ▶ $x_1, \dots, x_n$ son constantes conocidas.
 - ▶ Linealidad en los coeficientes β_0 y β_1 .
 - ▶ Errores aleatorios en las observaciones (independencia).
 - ▶ El error tiene distribución normal con media cero y varianza constante σ^2 (normalidad - homocedasticidad).
- ▶ De esta forma, la variable aleatoria $Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, tiene la siguiente distribución

$$Y_i|x_i \sim N(\beta_0 + \beta_1 x_i, \sigma^2), \quad i = 1, \dots, n,$$

y posee las siguientes características:

- ▶ $\mathbb{E}[Y_i|x_i] = \mathbb{E}[\beta_0 + \beta_1 X_i + \varepsilon_i|x_i] = \beta_0 + \beta_1 x_i$.
- ▶ $Var(Y_i|x_i) = Var(\beta_0 + \beta_1 x_i + \varepsilon_i|x_i) = Var(\varepsilon_i) = \sigma^2$.


Regresión Lineal Simple



Regresión Lineal Simple: Estimación

- Método de mínimos cuadrados ordinarios (MCO): Minimizar

$$Q = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad \text{en relación a } \boldsymbol{\beta} = (\beta_0, \beta_1)^\top$$



Regresión Lineal Simple: Estimación

- ▶ Dado el modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad i = 1, \dots, n.$$

- ▶ Queremos minimizar: $Q = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$.
- ▶ Calculando las derivadas en relación a β_0 y β_1 :

$$\begin{cases} S(\beta_0) = 2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i). \\ S(\beta_1) = 2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i). \end{cases}$$

Conocidas como las **Ecuaciones normales del modelo**.

- ▶ Igualando a cero, obtenemos los siguientes estimadores:

$$\begin{cases} \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}. \\ \hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n y_i (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{XY}}{S_{XX}}. \end{cases}$$

- ▶ Si x e y están positivamente relacionadas en la muestra, entonces $\hat{\beta}_1$ será positiva.

Regresión Lineal Simple: Estimación

- ▶ Note que el método de MCO no requiere suposiciones para la distribución de los errores.
- ▶ Se puede probar que sobre las suposiciones consideradas (independencia, normalidad y homocedasticidad) los estimadores de MCO de β coinciden con los estimadores de máxima verosimilitud.
- ▶ Es posible mostrar que las distribuciones de $\hat{\beta}_0$ y $\hat{\beta}_1$ son normales:

$$\hat{\beta}_0 \sim N\left(\beta_0, \frac{\sigma^2}{n} \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right) \quad y \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

- ▶ Estos estimadores satisfacen:
 - ▶ **Insesgados:** $\mathbb{E}[\hat{\beta}_j] = \beta_j, \quad j = 0, 1.$
 - ▶ **Consistentes:** $\lim_{n \rightarrow \infty} Var(\hat{\beta}_j) = 0, \quad j = 0, 1.$

Regresión Lineal Simple: Estimación

- ▶ Adicionalmente, la covarianza entre $\hat{\beta}_0$ y $\hat{\beta}_1$ es

$$\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\sigma^2 \frac{\bar{x}}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

- ▶ Un estimador para σ^2 puede ser determinado por el método de máxima verosimilitud.
- ▶ Consideraremos el siguiente estimador de σ^2 :

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

- ▶ Propiedades:
 - ▶ Este estimador es insesgado y consistente.
 - ▶ La distribución de la variable aleatoria $\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{(n-2)}$.
 - ▶ $\hat{\sigma}^2$ es independiente de $\hat{\beta}_0$ y $\hat{\beta}_1$.

Regresión Lineal Simple: Ejemplo


Ejemplo: Peso del arroz

- Modelo que le permita al productor predecir la cantidad de arroz resultante después del arroz ser sometido al proceso de secado.

$$s_i = \beta_0 + \beta_1 h_i + \varepsilon_i, \quad i = 1, \dots, 124.$$

- Las estimativas de los coeficientes de regresión son:

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{31805,00}{36433,67} = 0,873 \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = -19,626.$$



► Interpretación:

- $\hat{\beta}_1$: por cada kg que se incremente en la cantidad de arroz húmedo, se espera un incremento de 0.873 kg en la cantidad de arroz seco.
- Para obtener 1kg de arroz seco es necesario $1/0,873 = 1,145$ kg de arroz húmedo.

Regresión Lineal Simple: Ejemplo


Ejemplo: Pruebas de esfuerzo cardiopulmonar

- Suponga que ajustamos el siguiente modelo para los datos de las pruebas de esfuerzo cardiopulmonar sin considerar las etiologías

$$VO2_i = \beta_0 + \beta_1 \text{carga}_i + \varepsilon_i, \quad i = 1, \dots, 124.$$

Las estimativas de los coeficientes de regresión son:

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}} = \frac{6520,771}{75838,71} = 0,086$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6,563.$$



Regresión Lineal Simple: Ejemplo

Interpretación:

- ▶ Recordemos que para el modelo propuesto:

$$\mathbb{E}[Y_i|x_i] = \beta_0 + \beta_1 x_i, \quad i = 1, \dots, n.$$

- ▶ Luego un estimador para la esperanza condicional es

$$\widehat{\mathbb{E}[Y_i|x_i]} = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

- ▶ $\hat{\beta}_0$: Valor esperado en el consumo de oxígeno en pacientes cuya carga utilizada en la caminadora ergométrica es 0.
- ▶ $\hat{\beta}_1$: Incremento en el valor esperado del consumo de oxígeno para un aumento en una unidad en la carga utilizada.
- ▶ La carga influencia positivamente el consumo de oxígeno.

Regresión Lineal Simple

Observaciones:

- ▶ Los coeficientes de MCO cambian de forma totalmente predecible cuando cambiamos las unidades de medida.
- ▶ Si la variable dependiente (Y) se multiplica por c , entonces los coeficientes MCO del nuevo modelo ajustado también se multiplican por c .
- ▶ Si la variable independiente (x) se multiplica por c , entonces $\hat{\beta}_1$ se divide por c y $\hat{\beta}_0$ no cambia.

Regresión Lineal Simple: Inferencia para β

- Las distribuciones de $\hat{\beta}_0$ y $\hat{\beta}_1$ son:

$$\hat{\beta}_0 \sim N\left(\beta_0, \frac{\sigma^2}{n} \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right) \quad \text{y} \quad \hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}\right)$$

- Considerando $d = \sum_{i=1}^n x_i^2 / n \sum_{i=1}^n (x_i - \bar{x})^2$ y estandarizando, tenemos:

$$\frac{\hat{\beta}_0 - \beta_0}{\sqrt{\sigma^2 d}} \sim N(0, 1) \quad \text{y} \quad \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2}} \sim N(0, 1).$$

- Como σ^2 es desconocido, puede ser estimado por $\hat{\sigma}^2$,

$$\frac{\hat{\beta}_0 - \beta_0}{\sqrt{\hat{\sigma}^2 d}} \sim t_{(n-2)} \quad \text{y} \quad \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\hat{\sigma}^2 / \sum_{i=1}^n (x_i - \bar{x})^2}} \sim t_{(n-2)}.$$

Regresión Lineal Simple: Intervalos de confianza

- Por lo tanto un intervalo de confianza para β_0 es dado por:

$$IC(\beta_0, 1 - \alpha) = \hat{\beta}_0 \mp t_{(n-2, 1-\alpha/2)} \sqrt{\frac{\hat{\sigma}^2}{n} \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}.$$

- De manera análoga, un intervalo de confianza para β_1 es:

$$IC(\beta_1, 1 - \alpha) = \hat{\beta}_1 \mp t_{(n-2, 1-\alpha/2)} \sqrt{\frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}.$$

Regresión Lineal Simple: Ejemplo

Ejemplo: Pruebas de esfuerzo cardiopulmonar

- ▶ La estimativa de σ^2 es:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 3,579.$$

- ▶ Luego, intervalos de confianza de 95 % para β_0 y β_1 son dados por:

$$IC(\beta_0, 0,95) = [6,563 - 1,980(0,356), 6,563 + 1,980(0,356)] = [5,341, 7,785]$$

$$IC(\beta_1, 0,95) = [0,086 - 1,980(0,007), 0,086 + 1,980(0,007)] = [0,072, 0,100]$$

Interpretación:

- ▶ El consumo de oxígeno para pacientes sometidos a carga 0 tiende a variar entre 5,859 y 7,268 $ml/(kg \cdot min)$.
- ▶ El aumento esperado en el consumo para un aumento en una unidad de la carga tiende a estar entre 0,072 y 0,100 $ml/(kg \cdot min)$.

Regresión Lineal Simple: Prueba de hipótesis

- Suponga que queremos probar las siguientes hipótesis:

$$H_0 : \beta_0 = b_0 \quad \text{vs.} \quad H_1 : \beta_0 \neq b_0,$$

en que b_0 es un valor fijo.

- El estadístico de prueba será: $t = \frac{\hat{\beta}_0 - b_0}{\sqrt{\hat{\sigma}^2 d}},$

$$d = \frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}.$$

- Rechazamos H_0 si $|t_{\text{obs}}| \geq t_{\text{crit}}$, en que $t_{\text{crit}} = t_{(n-2, 1-\alpha/2)}$.
- De modo equivalente, rechazamos H_0 si el valor- $p \leq \alpha$, en que el valor- $p = P(|t_{(n-2)}| \geq |t_{\text{obs}}|)$.
- De manera análoga podemos probar la hipótesis

$$H_0 : \beta_1 = b_1 \quad \text{vs.} \quad H_1 : \beta_1 \neq b_1.$$

Regresión Lineal Simple: Valores ajustados

El **valor ajustado** para la i -ésima observación (que coincide con el valor estimado de $\mu_{Y_i|x_i} = \mathbb{E}[Y_i|x_i]$) es dado por:

$$\widehat{\mu_{Y_i|x_i}} = \widehat{\mathbb{E}[Y_i|x_i]} = \hat{\beta}_0 + \hat{\beta}_1 x_i.$$

- Para el **ejemplo** de esfuerzo cardiopulmonar, el valor ajustado para el individuo i es dado por:

$$\widehat{\mu_{VO2_i}} = 6,563 + 0,086 \text{ carga}_i, \quad i = 1, \dots, 124.$$

- Note que $\widehat{\mu_{Y_i|x_i}}$ es una variable aleatoria con $\mathbb{E}[\widehat{\mu_{Y_i|x_i}}] = \beta_0 + \beta_1 x_i$ y varianza dada por:

$$\begin{aligned} \text{Var}(\widehat{\mu_{Y_i|x_i}}) &= \text{Var}(\hat{\beta}_0) + x_i^2 \text{Var}(\hat{\beta}_1) + 2x_i \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) \\ &= \sigma^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{j=1}^n (x_j - \bar{x})^2} \right). \end{aligned}$$

Regresión Lineal Simple: Valores ajustados

Intervalo de confianza para la media de la respuesta

- ▶ Un intervalo de confianza para $\mu_{Y_i|x_i} = \mathbb{E}[Y_i|x_i]$ es dado por:

$$IC(\mu_{Y_i|x_i}, 1 - \alpha) = \widehat{\mu_{Y_i|x_i}} \mp t_{(n-2, 1-\alpha/2)} \sqrt{\widehat{\sigma}^2 \left(\frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{j=1}^n (x_j - \bar{x})^2} \right)}$$

- ▶ Que en R puede ser calculado a través de la función
`predict(modelo, interval = "confidence")`
- ▶ Para los 4 primeros individuos del ejemplo de los datos de pruebas de esfuerzo cardiopulmonar retorna:


	modelo	lwr	upr
1	10.09	9.75	10.43
2	11.38	11.01	11.74
3	7.25	6.64	7.86
4	11.12	10.77	11.47

Regresión Lineal Simple: Valores ajustados

Ejemplo: Pruebas de esfuerzo cardiopulmonar

- En el ejemplo podemos realizar el gráfico de los intervalos de confianza de los valores ajustados usando el siguiente comando:

```
ggplot(data=datos, aes(x=carga,  
y=consumo.oxygeno)) + geom_point() +  
geom_smooth(method="lm", se=TRUE)
```



Regresión Lineal Simple: Predicción

- ▶ Ahora estamos interesados en predecir una nueva respuesta y_{nuevo} cuando el valor de la variable explicativa es conocida x_{nuevo} .

El valor predicho para y_{nuevo} , denotado por $\hat{y}_{\text{nuevo}}$ es dado por:

$$\hat{y}_{\text{nuevo}} = \hat{\beta}_0 + \hat{\beta}_1 x_{\text{nuevo}}.$$

- ▶ El intervalo de predicción de $(1 - \alpha) \cdot 100\%$ es dado por:

$$IC(Y_{\text{nuevo}}, 1 - \alpha) = \hat{y}_{\text{nuevo}} \mp t_{(n-2, 1-\alpha/2)} \sqrt{\hat{\sigma}^2 \left(1 + \frac{1}{n} + \frac{(x_{\text{nuevo}} - \bar{x})^2}{\sum_{j=1}^n (x_j - \bar{x})^2} \right)}$$

- ▶ El intervalo de predicción puede ser obtenido:

```
y.nuevo = predict(modelo, interval="prediction",  
newdata=data.frame(nombre.x=x.nuevo))
```

Regresión Lineal Simple: Predicción

Ejemplo: Pruebas de esfuerzo cardiopulmonar

- ▶ Suponga que estamos interesados en saber cual es el valor predicho del consumo de oxígeno para cargas iguales a 40 y 100.
- ▶ Los valores predichos pueden ser calculados a través de:
 $\widehat{VO2}_i = 6,563 + 0,086 \text{ carga}_i$, obteniendo

$$\widehat{VO2}_i = 6,563 + 0,086(40) = 10,003$$


$$\widehat{VO2}_i = 6,563 + 0,086(100) = 15,162$$

- ▶ Luego, el intervalo de predicción es calculado usando el siguiente comando:

```
predict(modelo, interval="prediction", newdata=
        data.frame(carga=c(40,100)))
```

Regresión Lineal Simple: Predicción

- Gráfico de los valores predichos junto con el intervalo de predicción.



Regresión Lineal Simple: Predicción

Observaciones:

- ▶ En los modelos de regresión lineal simple, las predicciones se basan en la relación encontrada entre la variable dependiente y la variable independiente observada en los datos.
- ▶ Aunque es posible realizar predicciones para valores de la variable independiente (x_i) que están fuera del rango de los valores observados, es importante tener en cuenta que:
 - ▶ Al extrapolar más allá del rango de los datos de observados, existe un mayor grado de incertidumbre (mayor varianza).
 - ▶ Estamos asumiendo que la relación (lineal) entre las variables se mantiene constante más allá de los valores observados, lo cual puede no ser cierto en todos los casos.

Regresión Lineal Simple: Sumas de cuadrados

- ▶ Uno de los objetivos del modelo es **explicar la variabilidad** de los datos a través de la parte sistemática $f(x_i) = \beta_0 + \beta_1 x_i$. Una forma de medir tal característica es comparar las sumas cuadráticas.
- ▶ **Suma cuadrática total (SCT):**

$$SCT = \sum_{i=1}^n (y_i - \bar{y})^2.$$

- ▶ La SCT puede ser descompuesta como:

$$\begin{aligned} SCT &= \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n [(y_i - \hat{y}_i) + (\hat{y}_i - \bar{y})]^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 + 2 \sum_{i=1}^n (y_i - \hat{y}_i)(\hat{y}_i - \bar{y}) + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{SC} \end{aligned}$$

Regresión Lineal Simple: Sumas de cuadrados

► Suma cuadrática de regresión (SCR):

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2,$$

cuantifica qué tan lejos está la recta de regresión estimada $\hat{y}_i$ de la media muestral $\bar{y}$.

► Suma cuadrática del error (SCE):

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

cuantifica cuánto varían los valores observados y_i alrededor de la recta de regresión estimada $\hat{y}_i$.

[black]sinteflightgreen **Observación:** Si cambiamos el modelo, pero no los datos, la SCT se mantiene, mientras que la SCR y SCE podrían cambiar.

Regresión Lineal Simple: Sumas de cuadrados

- ▶ El **teorema de Cochran** establece que si y_i es seleccionado de una población $N(\mu, \sigma^2)$. La SCT se descompone en k sumas cuadráticas que denotaremos como $SC_q, q = 1, \dots, k$. Cada una de ellas con gl_q grados de libertad.
- ▶ Por lo tanto, SC_q/σ^2 tiene distribución Ji-Cuadrada con gl_q grados de libertad, $\chi^2_{(gl_q)}$.
- ▶ Como la SCT tiene $(n - 1)$ grados de libertad, entonces

$$\sum_{q=1}^k gl_q = n - 1.$$

Regresión Lineal Simple: Sumas de cuadrados

- ▶ Por otro lado, la SCT fue descompuesta en $k = 2$ sumas cuadráticas, $SCT = SCR + SCE$. Cada una de ellas:
 - ▶ SCR posee $p - 1$ grados de libertad, p es el número de coeficientes de regresión (β 's).
 - ▶ SCE tiene $n - p$ grados de libertad.
- ▶ Puede mostrarse que la **Media Cuadrática del Error (MCE)** es:


$$MCE = \frac{SCE}{n - 2} = \hat{\sigma}^2 \quad \text{y} \quad \mathbb{E}(MCE) = \mathbb{E}\left(\frac{SCE}{n - 2}\right) = \sigma^2.$$

- ▶ Mientras que la **Media Cuadrática de Regresión (MCR)** es:


$$MCR = \frac{SCR}{2 - 1} \quad \text{y} \quad \mathbb{E}(MCR) = \mathbb{E}\left(\frac{SCR}{1}\right) = \sigma^2 + \beta_1^2 \sum_{i=1}^n (x_i - \bar{x})^2$$

Regresión Lineal Simple: Sumas de cuadrados


Usando un modelo para explicar la variación de y : (a) datos para los cuales toda la variación es justificada por la relación entre x e y ; (b) datos para los cuales gran parte de la variación es justificada; (c) datos para los cuales poca variación es justificada.



(a)



(b)



(c)

Regresión Lineal Simple: Coeficiente de determinación R^2

- ▶ Recordemos que: $SCT = SCR + SCE$.
- ▶ Lo deseable es que la SCE sea lo más pequeña posible con respecto a la SCT .
- ▶ Una medida de la **calidad de ajuste del modelo** es el coeficiente de determinación R^2 , que se lo define como

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}.$$

- ▶ Ese coeficiente asume valores entre 0 y 1.
[black]sinteflightgreen **Potencia de explicación del modelo:** $R^2 \cdot 100\%$, porcentaje de la variabilidad de y observada que puede ser explicada por el modelo de regresión lineal simple.

Regresión Lineal Simple: Coeficiente de determinación R^2

- ▶ Entre menor es la SCE más grande es la potencia de explicación del modelo, y consecuentemente, mejor el modelo de regresión lineal simple consigue explicar la variación en y .
- ▶ La inclusión de muchas variables, incluso si tienen poco poder explicativo sobre la variable dependiente, aumentará el valor de R^2 .
- ▶ Por lo tanto, una alternativa un poco mejor es el R^2 ajustado, $\bar{R}^2$:

$$\bar{R}^2 = 1 - \frac{(n-1)}{(n-p)}(1 - R^2),$$

en que n es el tamaño de la muestra y p es el número de β 's. En regresión lineal simple, $p = 2$.

Regresión Lineal Simple: Coeficiente de determinación R^2

Observaciones:

- ▶ Note que el coeficiente de determinación R^2 es igual al coeficiente de correlación lineal R al cuadrado.
- ▶ Valores de R^2 muy grandes pueden hacernos pensar que el modelo, lineal, es mejor para esos datos y no continuemos explorando. Sin embargo, puede que nos esté faltando alguna covariable.
- ▶ En aplicaciones es frecuente ver R^2 bastante bajos, pero eso no significa que el modelo sea inútil o esté mal (ni que un modelo con R^2 alto esté muy bien).


Regresión Lineal simple: Coeficiente de determinación R^2

Ejemplo: Considere los datos de Anscombe (1973)

Obs.	A		B		C		D	
	x_i	y_i	x_i	y_i	x_i	y_i	x_i	y_i
1	10.00	8.04	10.00	9.14	10.00	7.46	8.00	6.58
2	8.00	6.95	8.00	8.14	8.00	6.77	8.00	5.76
3	13.00	7.58	13.00	8.74	13.00	12.74	8.00	7.71
4	9.00	8.81	9.00	8.77	9.00	7.11	8.00	8.84
5	11.00	8.33	11.00	9.26	11.00	7.81	8.00	8.47
6	14.00	9.96	14.00	8.10	14.00	8.84	8.00	7.04
7	6.00	7.24	6.00	6.13	6.00	6.08	8.00	5.25
8	4.00	4.20	4.00	3.10	4.00	5.39	19.00	12.50
9	12.00	10.84	12.00	9.13	12.00	8.15	8.00	5.56
10	7.00	4.82	7.00	7.26	7.00	6.42	8.00	7.91
11	5.00	5.68	5.00	4.74	5.00	5.73	8.00	6.89

Regresión Lineal simple: Coeficiente de determinación R^2

Ejemplo: Considere los datos de Anscombe (1973)



Regresión Lineal simple: Coeficiente de determinación R^2





Ejemplo: Considere los datos de Anscombe (1973)

- ▶ Vamos a ajustar para cada conjunto de datos el modelo

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2), i = 1, \dots, n.$$

- ▶ En el conjunto de datos A, el modelo parece adecuado.
- ▶ En el conjunto B, un modelo cuadrático sería más conveniente.
- ▶ En el conjunto C, el modelo parece ajustarse bien a los datos, con excepción del punto (12, 12.74) que puede ser considerado **outier**.
- ▶ En el conjunto D, el coeficiente de regresión β es significativo apenas en función de (19, 12.50).
- ▶ Para los cuatro conjuntos de datos, tenemos que $\hat{\beta}_0 = 3,00$, $\hat{\beta}_1 = 0,50$, $\hat{\sigma}^2 = 1,528$, $R^2 = 0,667$ y $\bar{R}^2 = 0,630$, lo que evidencia que el coeficiente de determinación R^2 no siempre es adecuado para medir la adecuación de ajuste del modelo.

Regresión Lineal Simple: Coeficiente de determinación R^2



Regresión Lineal Simple: Coeficiente de determinación R^2

Observaciones:

- ▶ Los valores atípicos (outliers) pueden influir fuertemente en los resultados tanto del valor de R^2 como en el coeficiente de correlación lineal R , lo que puede llevar a conclusiones erróneas.
- ▶ Los coeficientes R^2 y R solo miden la fuerza de las relaciones lineales. Si la relación entre variables es **no lineal**, el uso de estas medidas puede no representar con precisión la asociación.
- ▶ La interpretación de R^2 debe hacerse siempre en el contexto del problema en estudio. Un valor alto de R^2 puede ser significativo en algunas situaciones pero no en otras.
- ▶ Cuando se trabaja con múltiples covariables, la multicolinealidad (alta correlación entre predictores) puede llevar a valores inflados de R^2 y estimaciones de coeficientes inestables en modelos de regresión.

Regresión Lineal Simple: Análisis de varianza

- ▶ La **Tabla de Análisis de Varianza** (ANOVA) es utilizada en regresión para analizar la validez del modelo
 $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$.
- ▶ Prueba de hipótesis: $H_0 : \beta_1 = 0$ vs. $H_1 : \beta_1 \neq 0$.
- ▶ La tabla ANOVA es construida como sigue:

Fuentes de Variación	Grados de Libertad	Sumas Cuadráticas	Medias Cuadráticas	Estadístico de Prueba F
Regresión	$p - 1$	$\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	$\frac{SCR}{p-1}$	$F = \frac{MCR}{MCE}$
Error	$n - p$	$\sum_{i=1}^n (y_i - \hat{y}_i)^2$	$\frac{SCE}{n-p}$	
Total	$n - 1$	$\sum_{i=1}^n (y_i - \bar{y})^2$		

- ▶ En que $F \sim F_{(p-1, n-p)}$.
- ▶ Rechazamos H_0 si $F_{obs} > F_{(p-1, n-p, 1-\alpha)}$ o si $\text{valor-}p = P(F_{(p-1, n-p)} \geq F_{obs}) \leq \alpha$.
- ▶ Para el modelo de regresión lineal simple, podemos construir la tabla ANOVA en R usando la función

`anova(modelo)`.

Regresión Lineal Simple: Análisis de varianza

Ejemplo: Pruebas de esfuerzo cardiopulmonar

- ▶ Calculemos primero cada una de las sumas cuadráticas:

$$SCT = 997,28, \quad SCR = 560,67, \quad SCE = 436,61.$$

- ▶ La tabla ANOVA

Fuentes de Variación	Grados de Libertad	Sumas Cuadráticas	Medias Cuadráticas	Estadístico de Prueba F
Regresión	1	560,67	560,67	$F_{obs} = 156,67$
Error	122	436,61	3,579	
Total	123	997,28		

- ▶ Considerando $\alpha = 0,05$, obtenemos que $F_{(1,122,0,05)} = 3,919$, por lo tanto rechazamos la hipótesis nula que postula que $\beta_1 = 0$.
- ▶ Para esta prueba el valor- $p = P(F_{(1,122)} \geq 156,67) \approx 0$.

Regresión Lineal Simple: Códigos de R

- ▶ Para leer el conjunto de datos en R usamos el siguiente comando:

```
datos =  
read.table("localizacion/Etiologias-cardiacas.txt")
```

- ▶ Asignamos etiquetas a cada columna, como sigue:

```
names(datos) = c('etiologia', 'carga',  
                 'consumo.oxigeno')
```

- ▶ Las estimativas del modelo de regresión lineal simple pueden ser obtenidas a través de la función `lm()`:

```
modelo = lm(cosumo.oxigeno ~ carga, data=datos)
```

- ▶ Las estimativas de los coeficientes de regresión son recuperadas a través del siguiente comando:

```
coefficients(modelo)
```

- ▶ El cual retorna un vector con las estimativas de β_0 y β_1 .
- ▶ Utilizando la función `summary(modelo)`, obtenemos el resultado mostrado a continuación.

Regresión Lineal Simple: Salida de R

Call:

```
lm(formula = consumo.oxigeno ~ carga, data = datos)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.7327	-1.1680	-0.3317	1.1524	6.5075

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.563493	0.356037	18.43	<2e-16 ***
carga	0.085982	0.006869	12.52	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.892 on 122 degrees of freedom

Multiple R-squared: 0.5622, Adjusted R-squared: 0.5586

F-statistic: 156.7 on 1 and 122 DF, p-value: < 2.2e-16

Regresión Lineal Simple: Suposiciones

- ▶ Las principales suposiciones del modelo de regresión lineal son:
 - ▶ Homocedasticidad (de los errores).
 - ▶ Independencia (correlación nula) de los errores.
 - ▶ Normalidad de los errores.
- ▶ ¿Cómo verificar las suposiciones del modelo?
- ▶ ¿Cómo proceder si una o más suposiciones no son válidas de manera satisfactoria?


Regresión Lineal Simple: Análisis de residuos

- ▶ Sea $\hat{y}_i$ el valor ajustado de y_i . Estos dos valores no son necesariamente iguales, pues uno es calculado utilizando los datos ($\hat{y}_i$) y el otro es observado (y_i) una vez que se fija x_i .
- ▶ Por tanto, la diferencia $y_i - \hat{y}_i$ es una estimativa del error ε_i , denominada **residuo**, esto es,

$$r_i = \hat{\varepsilon}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i, \quad i = 1, \dots, n.$$

- ▶ Si $r_i > 0$, la recta ajustada infrapredice (pasa por debajo del punto (x_i, y_i)).
- ▶ Si $r_i < 0$, la recta ajustada sobrepredice (pasa por encima del punto (x_i, y_i)).
- ▶ Si $r_i = 0$, situación ideal, pero difícil de ocurrir.

Regresión Lineal Simple: Análisis de residuos



Regresión Lineal Simple: Análisis de residuos

► Adicionalmente, $\sum_{i=1}^n r_i = 0$.

► Deducción:

$$\begin{aligned}\sum_{i=1}^n r_i &= \sum_{i=1}^n (y_i - \hat{y}_i) \\ &= \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \\ &= \sum_{i=1}^n y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_{i=1}^n x_i \\ &= n\bar{y} - n(\bar{y} - \hat{\beta}_1 \bar{x}) - n\hat{\beta}_1 \bar{x} \\ &= 0.\end{aligned}$$

Regresión Lineal Simple: Análisis de residuos

- Sobre los supuestos del modelo

$$r_i \sim N(0, \sigma^2(1 - h_{ii})) \quad \text{y} \quad \text{Cov}(r_i, r_j) = -\sigma^2 h_{ij}, \forall i \neq j,$$

en que h_{ij} es el elemento de la i -ésima fila, j -ésima columna de la matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$, conocida como la **matriz "hat"**.

- Para el modelo de regresión lineal simple

$$\mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}.$$

- Note que los residuos obtenidos son **correlacionados**.

Regresión Lineal Simple: Análisis de residuos

- Defina

$$V_i = \frac{R_i}{\sqrt{\hat{\sigma}^2(1 - h_{ii})}}.$$

- Puede mostrarse que R_i y $\hat{\sigma}^2$ no son variables aleatorias independientes.
- Mas $\sigma_{(i)}^2 = \hat{\sigma}^2 \left(\frac{n - p - V_i^2}{n - p - 1} \right)$ y R_i son variables aleatorias independientes.
- Luego,

$$T_i = \frac{R_i}{\sqrt{\hat{\sigma}_{(i)}^2(1 - h_{ii})}} \sim t_{(n-p)}$$

sobre la validez de las hipótesis del modelo. Este residuo es conocido como **Residuo Studentizado**.

- Recuerde que si $\nu \geq 30$, entonces $t_{(\nu)} \approx N(0, 1)$.


Regresión Lineal Simple: Análisis de residuos

¿Qué y cómo observar los residuos?

- ▶ Gráfico de dispersión de los residuos versus el índice de la observación: Identificación de dependencia/ tendencia/ correlación.
- ▶ Gráfico de dispersión de los residuos versus los valores ajustados: Homocedasticidad.
- ▶ Boxplot y/o gráfico de cuantiles-cuantiles (qqplot): Simetría, identificación de “outliers” y multimodalidad.
- ▶ Problema en el gráfico de cuantiles-cuantiles: A menudo, es difícil evaluar visualmente la proximidad de los cuantiles en un gráfico de cuantiles-cuantiles.
- ▶ Una solución para abordar este problema es crear bandas de confianza (gráficos de envelope).


Regresión Lineal Simple: Análisis de residuos

- ¿Cómo esperamos que se comporten los residuos Studentizados sobre la **validad de los supuestos** del modelo?




Regresión Lineal Simple: Análisis de residuos

- ¿Cómo esperamos que se comporten los residuos Studentizados ante la **falta de independencia** de los errores?




Regresión Lineal Simple: Análisis de residuos

- ¿Cómo esperamos que se comporten los residuos Studentizados ante la **falta de homocedasticidad** de los errores?




Regresión Lineal Simple: Análisis de residuos

- ¿Cómo esperamos que se comporten los residuos Studentizados ante la **falta de normalidad** de los errores? Los errores poseen distribución $t_{(3)}$ (colas pesadas).



Regresión Lineal Simple: Análisis de residuos

- ¿Cómo esperamos que se comporten los residuos Studentizados ante la **falta de normalidad** de los errores? Los errores poseen distribución normal asimétrica (positiva).



Regresión Lineal Simple: Análisis de residuos


- Para calcular los residuos Studentizados utilizamos la función de R,

`rstudent(modelo)`

- Otra alternativa sería utilizar la función de R disponible en el archivo `residuos-norm.R`, que retorna los gráficos de diagnóstico a través del comando

`diagnorm(modelo)`


Ejemplo: Pruebas de esfuerzo cardiopulmonar



Regresión Lineal Simple: Análisis de residuos

Ejemplo: Pruebas de esfuerzo cardiopulmonar

- ▶ No hay correlación entre los residuos.
- ▶ Se observa una heterocedasticidad “leve” en los residuos.
- ▶ Aparentemente, los residuos muestran una distribución asimétrica positiva.
- ▶ Probablemente existe un efecto de grupo que no ha sido capturado por el modelo utilizado.



Actividad práctica: regresión lineal

- ▶ Formen grupos y utilicen el dataset Credit o Auto.
- ▶ Ajusten un modelo de regresión lineal simple y uno múltiple.
- ▶ Realicen diagnóstico gráfico del modelo.
- ▶ Evalúen heterocedasticidad y, si corresponde, usen errores robustos.
- ▶ Elaboren conclusiones sobre el modelo final.

Tiempo de trabajo: 30 minutos
Socialización: 5 minutos por grupo

Actividad práctica: código guía

```
library(ISLR2)
library(lmtest)
library(sandwich)

data(Credit)

modelo <- lm(Balance ~ Income + Limit + Rating + Age,
             data = Credit)

summary(modelo)

plot(modelo)

bptest(modelo)

coeftest(modelo,
          vcov = vcovHC(modelo, type = "HC1"))
```

Preguntas para interpretar

- ▶ ¿Cuál es la variable respuesta?
- ▶ ¿Qué predictores parecen estadísticamente significativos?
- ▶ ¿Cómo se interpreta el coeficiente principal del modelo?
- ▶ ¿Hay evidencia de heterocedasticidad?
- ▶ ¿Las conclusiones cambian al usar errores robustos?

Un modelo útil debe ser estimado, diagnosticado e interpretado.

Fuentes bibliográficas

- ▶ James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R*. 2nd ed. Springer.
- ▶ Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer.