

Introducción al Análisis de Clustering

Distancias, similaridades, k-means, clustering jerárquico y criterios de enlace

Clase de Estadística Multivariante

Objetivos de la clase

- Comprender qué es el clustering y por qué pertenece al aprendizaje no supervisado.
- Distinguir entre distancia, disimilitud y similaridad.
- Conocer las principales métricas usadas en clustering.
- Entender manualmente cómo funcionan k-means y el clustering jerárquico.
- Diferenciar centroide, medoide y criterios de enlace.
- Interpretar métodos como Ward, average, complete, single y centroid linkage.
- Evaluar el número y la calidad de los clusters.

¿Qué es clustering?

El **clustering** es un conjunto de métodos cuyo objetivo es agrupar observaciones similares entre sí.

A diferencia de la clasificación supervisada, en clustering no existe una variable respuesta conocida.

Dado un conjunto de datos:

$$X = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

se busca formar grupos tales que:

alta similitud dentro del grupo

alta diferencia entre grupos

Clustering como aprendizaje no supervisado

En aprendizaje no supervisado:

Y no está disponible

Solo se observan variables explicativas o características:

$$X_1, X_2, \dots, X_p$$

El objetivo no es predecir una respuesta, sino descubrir estructura interna en los datos.

Ejemplos frecuentes:

- segmentación de clientes;
- agrupamiento de países según indicadores socioeconómicos;
- clasificación exploratoria de pacientes;
- análisis de expresión génica;
- agrupamiento de documentos o textos;
- detección de perfiles de comportamiento.

Flujo general de un análisis de clustering

Un análisis de clustering no comienza con el algoritmo.

El flujo recomendado es:

- 1 definir el objetivo analítico;
- 2 seleccionar variables relevantes;
- 3 tratar datos faltantes;
- 4 decidir si se estandarizan las variables;
- 5 elegir una métrica de distancia o similaridad;
- 6 aplicar uno o varios algoritmos;
- 7 elegir el número de clusters;
- 8 evaluar estabilidad y calidad;
- 9 interpretar los grupos.

Importancia de la escala de las variables

Si las variables tienen escalas muy diferentes, una variable puede dominar el cálculo de distancias.

Ejemplo:

Ingreso anual: 10 000 a 80 000

Edad: 18 a 70

La distancia euclidiana estará dominada por el ingreso.

Por eso se suele estandarizar:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

donde:

$\bar{x}_j$ = media de la variable j

s_j = desviación estándar de la variable j

Distancia, disimilitud y similaridad

Distancia:

$$d(x_i, x_l)$$

mide separación entre dos observaciones.

Disimilitud:

$$\delta(x_i, x_l)$$

mide diferencia general. No siempre cumple todas las propiedades matemáticas de una distancia.

Similaridad:

$$s(x_i, x_l)$$

mide parecido. A mayor valor, mayor semejanza.

Muchas veces:

$$\text{disimilitud} = 1 - \text{similaridad}$$

Propiedades de una distancia métrica

Una distancia formal debe cumplir:

$$d(x_i, x_j) \geq 0$$

$$d(x_i, x_j) = 0 \iff x_i = x_j$$

$$d(x_i, x_j) = d(x_j, x_i)$$

$$d(x_i, x_k) \leq d(x_i, x_j) + d(x_j, x_k)$$

La última propiedad se llama **desigualdad triangular**.

No toda disimilitud usada en clustering es una distancia métrica estricta.

Distancia euclidiana

La distancia euclidiana es la más usada para datos cuantitativos continuos.

$$d(x_i, x_l) = \sqrt{\sum_{j=1}^p (x_{ij} - x_{lj})^2}$$

Ejemplo:

$$A = (2, 3), \quad B = (5, 7)$$

$$d(A, B) = \sqrt{(2 - 5)^2 + (3 - 7)^2}$$

$$d(A, B) = \sqrt{9 + 16} = 5$$

Es adecuada cuando las variables son numéricas, comparables y los grupos son aproximadamente compactos.

Distancia euclidiana cuadrada

La distancia euclidiana cuadrada es:

$$d^2(x_i, x_l) = \sum_{j=1}^p (x_{ij} - x_{lj})^2$$

Se usa frecuentemente en:

- k-means;
- método de Ward;
- criterios basados en suma de cuadrados.

Penaliza más las diferencias grandes que la distancia euclidiana simple.

Distancia Manhattan

La distancia Manhattan se define como:

$$d(x_i, x_l) = \sum_{j=1}^p |x_{ij} - x_{lj}|$$

Ejemplo:

$$A = (2, 3), \quad B = (5, 7)$$

$$d(A, B) = |2 - 5| + |3 - 7|$$

$$d(A, B) = 3 + 4 = 7$$

Ejemplo Práctico: Distancia Manhattan

Definición: Suma las diferencias absolutas horizontales y verticales entre dos puntos. Simula el recorrido real por calles en cuadrícula sin atravesar obstáculos.

Fórmula General

$$d = |x_2 - x_1| + |y_2 - y_1|$$

Caso de Estudio en Samborondón:

- **Punto A (Origen):** Esquina de urbanización en La Puntilla $\rightarrow (2, 3)$
- **Punto B (Destino):** Cafetería en Plaza Lagos $\rightarrow (5, 7)$


Ejemplo Práctico: Distancia Manhattan

Cálculo del Recorrido:

- ① **Eje Horizontal (X):** $|5 - 2| = 3$ cuadras / bloques.
- ② **Eje Vertical (Y):** $|7 - 3| = 4$ cuadras / bloques.
- ③ **Distancia Manhattan Total:** $3 + 4 = 7$ unidades de camino.

**Nota: La distancia Euclidiana (línea recta diagonal) sería de ≈ 5 unidades, pero es inviable al requerir atravesar construcciones reales.*

Representación Gráfica (Samborondón)



Distancia de Minkowski

La distancia de Minkowski generaliza varias distancias:

$$d(x_i, x_l) = \left(\sum_{j=1}^p |x_{ij} - x_{lj}|^q \right)^{1/q}$$

Casos particulares:

$q = 1 \Rightarrow$ distancia Manhattan

$q = 2 \Rightarrow$ distancia euclidiana

El parámetro q controla cómo se penalizan las diferencias grandes.

Distancia basada en correlación

En algunos problemas interesa comparar perfiles más que magnitudes.

La distancia basada en correlación puede definirse como:

$$d(x_i, x_l) = 1 - r(x_i, x_l)$$

donde:

$$r(x_i, x_l)$$

es la correlación entre dos observaciones.

Es útil cuando dos observaciones tienen el mismo patrón, aunque estén en escalas distintas.

Aplicaciones frecuentes:

- expresión génica;
- series temporales;
- perfiles de consumo;
- patrones de comportamiento.

Similaridad coseno

La similaridad coseno mide el ángulo entre dos vectores:

$$\text{coseno}(x_i, x_l) = \frac{x_i^\top x_l}{\|x_i\| \|x_l\|}$$

Una disimilitud asociada es:

$$d(x_i, x_l) = 1 - \text{coseno}(x_i, x_l)$$

Es especialmente útil cuando importa más la dirección que la magnitud.

Aplicaciones:

- documentos;
- minería de texto;
- datos dispersos;
- vectores de palabras o embeddings.

Distancia de Mahalanobis

La distancia de Mahalanobis incorpora la estructura de covarianza de las variables:

$$d_M(x_i, x_l) = \sqrt{(x_i - x_l)^\top S^{-1} (x_i - x_l)}$$

donde:

S = matriz de covarianzas

Es útil cuando las variables están correlacionadas.

Precaución:

- puede ser inestable si hay muchas variables;
- requiere estimar bien la matriz de covarianzas;
- puede fallar si S no es invertible.

Distancia de Gower

La distancia de Gower es útil para datos mixtos:

cuantitativos, binarios, ordinales y nominales

Su forma general es:

$$d_G(i, l) = \frac{\sum_{j=1}^p w_{ijl} d_{ijl}}{\sum_{j=1}^p w_{ijl}}$$

Es muy usada en:

- encuestas;
- datos clínicos;
- segmentación social;
- bases con variables numéricas y categóricas.

Métricas de Distancia en Análisis de Clústeres

1. Métricas Numéricas / Geométricas

- **Euclidiana:** Línea recta tradicional.
- **Manhattan:** Caminos en ángulos rectos.
 - *Uso:* Clústeres robustos a valores atípicos (*outliers*).
- **Mahalanobis:** Incorpora la covarianza.
 - *Uso:* Datos donde las variables están altamente correlacionadas.

2. Datos Binarios / Categóricos

- **Jaccard / Jaccard Binary:** Mide similitud de presencia/ausencia ignorando las ausencias dobles.
 - *Uso:* Minería de texto o sistemas de recomendación (carritos de compra).

3. Ecología y Abundancia de Especies

- **Bray-Curtis:** Mide la disimilitud en la abundancia de especies entre sitios. No se ve afectada por la ausencia conjunta de especies.
 - *Uso:* Clústeres en ecología comunitaria y microbioma ambiental.
- **Distancia de Hellinger:** Raíz cuadrada de las diferencias de frecuencias relativas. Evita el “*problema de la doble ausencia*” en datos con muchos ceros.
 - *Uso:* Análisis de coordenadas principales (PCoA) de datos genéticos o ecológicos.
- **Chi-cuadrado (χ^2):** Base del análisis de correspondencias.
 - *Uso:* Clústeres basados en tablas de contingencia.

La Paradoja de la Doble Ausencia

¿Qué es? Ocurre cuando dos sitios o muestras se consideran “similares” únicamente porque **ninguno de los dos** contiene ciertas especies o variables.

Ejemplo Práctico: Muestreo de Suelo en Samborondón

Comparamos la presencia de bacterias en tres muestras (S_1, S_2, S_3) para 100 especies:

- S_1 y S_2 comparten **0 especies** (son totalmente diferentes).
- Sin embargo, de las 100 especies analizadas, hay **90 especies que no están en ninguna de las dos muestras**.

El error Euclidiano

La distancia Euclidiana detecta que S_1 y S_2 coinciden en 90 ceros ($0 = 0$).

Resultado: El algoritmo agrupa a S_1 y S_2 como “muy similares” debido a lo que **no tienen**, distorsionando el clúster.

La Solución Asimétrica

Métricas de coeficientes asimétricos omiten el término $(0, 0)$.

- **Bray-Curtis** e **Hellinger** ignoran las ausencias mutuas.
- Evalúan la similitud basándose **solo en lo que sí está presente**.

Matriz de distancias

Muchos métodos comienzan con una matriz de distancias:

$$D = \begin{pmatrix} 0 & d_{12} & d_{13} & \cdots & d_{1n} \\ d_{21} & 0 & d_{23} & \cdots & d_{2n} \\ d_{31} & d_{32} & 0 & \cdots & d_{3n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ d_{n1} & d_{n2} & d_{n3} & \cdots & 0 \end{pmatrix}$$

Propiedades:

$$d_{ij} = d_{ji}$$

$$d_{ii} = 0$$

K-means: idea general

El método **k-means** divide las observaciones en K grupos no solapados:

$$C_1, C_2, \dots, C_K$$

tales que:

$$C_1 \cup C_2 \cup \dots \cup C_K = \{1, \dots, n\}$$

$$C_k \cap C_{k'} = \emptyset \quad \text{si } k \neq k'$$

Cada observación pertenece a un único cluster.

Función objetivo de k-means

K-means busca minimizar la variabilidad interna de los clusters:

$$\min_{C_1, \dots, C_K} \sum_{k=1}^K W(C_k)$$

Cuando se usa distancia euclidiana cuadrada:

$$W(C_k) = \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_{kj})^2$$

donde:

$$\bar{x}_{kj}$$

es la media de la variable j dentro del cluster k .

La idea central es formar grupos compactos alrededor de sus medias.

Centroide

El **centroide** de un cluster es el vector de medias de sus variables.

Si:

$$x_1 = (2, 4), \quad x_2 = (4, 6), \quad x_3 = (6, 8)$$

entonces el centroide es:

$$\bar{x} = \left(\frac{2 + 4 + 6}{3}, \frac{4 + 6 + 8}{3} \right)$$

$$\bar{x} = (4, 6)$$

El centroide puede no ser una observación real del conjunto de datos.

Algoritmo k-means

El algoritmo básico de k-means es:

- 1 Elegir el número de clusters K .
- 2 Inicializar K centroides.
- 3 Asignar cada observación al centroide más cercano.
- 4 Recalcular los centroides de los clusters.
- 5 Repetir los pasos 3 y 4 hasta que las asignaciones no cambien.

El algoritmo depende de la inicialización.

Por eso es recomendable ejecutarlo varias veces y elegir la solución con menor variación intra-cluster.

Ejemplo manual de k-means

Supongamos cuatro observaciones:

$$A = (1, 1), \quad B = (1, 2), \quad C = (4, 4), \quad D = (5, 4)$$

Queremos:

$$K = 2$$

Tomamos centroides iniciales:

$$m_1 = A = (1, 1)$$

$$m_2 = C = (4, 4)$$

Se calcula la distancia de cada punto a cada centroide y se asigna cada observación al centroide más cercano.

Ejemplo manual de k-means: asignación

Para $B = (1, 2)$:

$$d(B, m_1) = \sqrt{(1 - 1)^2 + (2 - 1)^2} = 1$$

$$d(B, m_2) = \sqrt{(1 - 4)^2 + (2 - 4)^2} = \sqrt{13}$$

Por tanto, B se asigna al cluster 1.

Para $D = (5, 4)$:

$$d(D, m_1) = \sqrt{(5 - 1)^2 + (4 - 1)^2} = 5$$

$$d(D, m_2) = \sqrt{(5 - 4)^2 + (4 - 4)^2} = 1$$

Por tanto, D se asigna al cluster 2.

Ejemplo manual de k-means: nuevos centroides

Después de la primera asignación:

$$C_1 = \{A, B\}$$

$$C_2 = \{C, D\}$$

Para el cluster 1:

$$A = (1, 1), \quad B = (1, 2)$$

$$m_1 = \left(\frac{1+1}{2}, \frac{1+2}{2} \right) = (1, 1.5)$$

Para el cluster 2:

$$C = (4, 4), \quad D = (5, 4)$$

$$m_2 = \left(\frac{4+5}{2}, \frac{4+4}{2} \right) = (4.5, 4)$$

Limitaciones de k-means

K-means es simple y útil, pero tiene limitaciones importantes:

- requiere elegir K antes del análisis;
- es sensible a la escala de las variables;
- es sensible a valores atípicos;
- puede converger a soluciones locales;
- favorece clusters esféricos y compactos;
- funciona mejor con variables cuantitativas.

No debe aplicarse como una caja negra.

K-medoids es similar a k-means, pero usa **medoides** en lugar de centroides.

Un **medoide** es una observación real del conjunto de datos que representa mejor a un cluster.

Diferencia clave:

centroide = media del cluster

medoide = observación real representativa

K-medoids suele ser más robusto frente a valores atípicos.

Centroide versus medoide

Aspecto	Centroide	Medoide
Definición	Media multivariante	Observación real
Pertenece a los datos	No siempre	Sí
Sensibilidad a outliers	Alta	Menor
Uso típico	K-means	K-medoids
Datos mixtos	Poco adecuado	Más flexible

Si los datos contienen valores extremos o variables mixtas, k-medoids puede ser más apropiado que k-means.

Clustering jerárquico

El clustering jerárquico produce una estructura en forma de árbol llamada:

dendrograma

No exige fijar inicialmente el número de clusters.

Existen dos enfoques principales:

- **aglomerativo**: comienza con n clusters y los va fusionando;
- **divisivo**: comienza con un único cluster y lo va dividiendo.

El enfoque más usado es el aglomerativo.

Clustering jerárquico aglomerativo

El procedimiento básico es:

- 1 cada observación inicia como su propio cluster;
- 2 se calcula la matriz de distancias;
- 3 se fusionan los dos clusters más cercanos;
- 4 se actualizan las distancias entre clusters;
- 5 se repite hasta obtener un único cluster.

El resultado es una secuencia anidada de particiones.

$$n \text{ clusters} \rightarrow n - 1 \rightarrow n - 2 \rightarrow \dots \rightarrow 1$$

Dendrograma

Un dendrograma representa gráficamente las fusiones entre observaciones o clusters.

La altura de la fusión indica el nivel de disimilitud.

fusión baja $\Rightarrow$ alta similitud

fusión alta $\Rightarrow$ baja similitud


Para obtener una partición final, se corta horizontalmente el dendrograma.

corte alto $\Rightarrow$ pocos clusters

corte bajo $\Rightarrow$ muchos clusters

Resultado del Clúster Jerárquico: Dendrograma

El eje vertical representa la **distancia de disimilitud** (métricas como Hellinger o Bray-Curtis). Las uniones más bajas indican muestras con alta similitud ecológica.



Interpretación: Se forman claramente 2 clústeres comerciales/ecológicos bien diferenciados al aplicar la línea de corte.

¿Qué es el linkage?

En clustering jerárquico, después de las primeras fusiones aparecen clusters con varias observaciones.

Por tanto, necesitamos definir la distancia entre dos clusters:

$$d(C_a, C_b)$$

A esta regla se le llama:

criterio de enlace

o

linkage

Los criterios más comunes son:

- single linkage;
- complete linkage;
- average linkage;
- centroid linkage;
- Ward.

Single linkage

Single linkage define la distancia entre dos clusters como la distancia mínima entre sus puntos:

$$d(C_a, C_b) = \min_{i \in C_a, l \in C_b} d(x_i, x_l)$$

Interpretación:

dos clusters son cercanos si al menos dos puntos están cerca

Ventaja:

- puede detectar formas alargadas o irregulares.

Desventaja:

- puede generar efecto de encadenamiento.

Complete linkage

Complete linkage define la distancia entre dos clusters como la distancia máxima entre sus puntos:

$$d(C_a, C_b) = \max_{i \in C_a, l \in C_b} d(x_i, x_l)$$

Interpretación:

dos clusters se fusionan si todos sus puntos son relativamente cercanos

Ventaja:

- produce clusters compactos.

Desventaja:

- puede fragmentar grupos grandes o alargados.

Average linkage

Average linkage usa el promedio de todas las distancias entre pares de puntos de dos clusters:

$$d(C_a, C_b) = \frac{1}{|C_a||C_b|} \sum_{i \in C_a} \sum_{l \in C_b} d(x_i, x_l)$$

Interpretación:

distancia promedio entre ambos grupos

Suele ser un compromiso entre single y complete linkage.

Ejemplo de average linkage

Supongamos:

$$C_a = \{A, B\}$$

$$C_b = \{C, D\}$$

y las distancias:

$$d(A, C) = 3, \quad d(A, D) = 5$$

$$d(B, C) = 4, \quad d(B, D) = 6$$

Entonces:

$$d(C_a, C_b) = \frac{3 + 5 + 4 + 6}{4}$$

$$d(C_a, C_b) = 4,5$$

Centroid linkage

Centroid linkage define la distancia entre dos clusters como la distancia entre sus centroides:

$$d(C_a, C_b) = d(\bar{x}_a, \bar{x}_b)$$

donde:

$$\bar{x}_a = \text{centroide de } C_a$$

$$\bar{x}_b = \text{centroide de } C_b$$

Es intuitivo, pero puede producir inversiones en el dendrograma.

Una inversión ocurre cuando una fusión posterior aparece a menor altura que una fusión anterior.

Método de Ward

El método de Ward fusiona los clusters cuya unión produce el menor aumento en la variabilidad interna.

Para dos clusters C_a y C_b :

$$\Delta(C_a, C_b) = W(C_a \cup C_b) - W(C_a) - W(C_b)$$

donde:

$$W(C) = \sum_{i \in C} \|x_i - \bar{x}_C\|^2$$

Ward elige la fusión con menor incremento en la suma de cuadrados intra-cluster.

Interpretación del método de Ward

Ward tiende a producir clusters:

- compactos;
- aproximadamente esféricos;
- relativamente balanceados;
- con baja variabilidad interna.

Su lógica es cercana a k-means:

minimizar variación dentro de los grupos

Diferencia principal:

k-means es particional

Ward es jerárquico

Comparación de criterios de enlace

Criterio	Definición
Single	Distancia mínima entre puntos
Complete	Distancia máxima entre puntos
Average	Promedio de distancias entre puntos
Centroid	Distancia entre centroides
Ward	Menor aumento de varianza interna

La elección del linkage puede cambiar completamente el dendrograma y la solución final.

Ejemplo manual de clustering jerárquico

Supongamos la siguiente matriz de distancias:

	<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>
<i>A</i>	0	2	6	10
<i>B</i>	2	0	5	9
<i>C</i>	6	5	0	4
<i>D</i>	10	9	4	0

La menor distancia es:

$$d(A, B) = 2$$

Por tanto, se fusionan primero:

$$\{A, B\}$$

Actualización de distancias

Luego quedan:

$$\{A, B\}, \quad \{C\}, \quad \{D\}$$

Si usamos single linkage:

$$d(\{A, B\}, C) = \min(d(A, C), d(B, C))$$

$$d(\{A, B\}, C) = \min(6, 5) = 5$$

$$d(\{A, B\}, D) = \min(d(A, D), d(B, D))$$

$$d(\{A, B\}, D) = \min(10, 9) = 9$$

Como:

$$d(C, D) = 4$$

la siguiente fusión es:

$$\{C, D\}$$

Misma matriz, distinto linkage

Para fusionar:

$$\{A, B\} \quad \text{con} \quad \{C, D\}$$

las distancias disponibles son:

$$d(A, C) = 6, \quad d(A, D) = 10$$

$$d(B, C) = 5, \quad d(B, D) = 9$$

Con single linkage:

$$\min(6, 10, 5, 9) = 5$$

Con complete linkage:

$$\max(6, 10, 5, 9) = 10$$

Con average linkage:

$$\frac{6 + 10 + 5 + 9}{4} = 7,5$$

K-means versus clustering jerárquico

Aspecto	K-means	Jerárquico
Tipo	Particional	Jerárquico
Requiere K inicial	Sí	No necesariamente
Salida	Clusters	Dendrograma
Representante	Centroide	Depende del linkage
Reasignación	Sí	No
Inicialización aleatoria	Sí	No usualmente
Interpretación visual	Media	Alta

Elección del número de clusters

Una de las decisiones más importantes es elegir K .

Métodos comunes:

- método del codo;
- índice silhouette;
- gap statistic;
- inspección del dendrograma;
- estabilidad por remuestreo;
- interpretación sustantiva.

No existe una única regla universal.

Método del codo

Se calcula la suma de cuadrados intra-cluster para distintos valores de K :

$$W_K = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \bar{x}_k\|^2$$

Luego se grafica:

K versus W_K

Se elige el punto donde la reducción de W_K empieza a estabilizarse.

Ese punto se interpreta como el “codo”.

Índice silhouette

Para cada observación i :

$a(i)$ = distancia promedio de i a su propio cluster

$b(i)$ = menor distancia promedio de i a otro cluster

El índice silhouette es:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Interpretación:

$s(i) \approx 1 \Rightarrow$ buena asignación

Medidas internas de calidad

Las medidas internas evalúan el clustering sin etiquetas externas.

Suma de cuadrados intra-cluster:

$$WSS = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \bar{x}_k\|^2$$

Suma de cuadrados entre clusters:

$$BSS = \sum_{k=1}^K n_k \|\bar{x}_k - \bar{x}\|^2$$

Relación total:

$$TSS = WSS + BSS$$

El índice Calinski-Harabasz se define como:

$$CH = \frac{BSS/(K - 1)}{WSS/(n - K)}$$

Interpretación:

- valores altos indican buena separación entre clusters;
- también indican baja dispersión interna;
- puede usarse para comparar distintos valores de K .

El índice Davies-Bouldin compara dispersión interna con separación entre clusters.

$$DB = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \left(\frac{S_k + S_l}{M_{kl}} \right)$$

donde:

S_k = dispersión del cluster k

M_{kl} = distancia entre los clusters k y l

Valores más bajos indican mejores soluciones.

Cuando existen etiquetas reales, se pueden comparar los clusters con esas clases.

Medidas comunes:

- Rand Index;
- Adjusted Rand Index;
- pureza;
- mutual information;
- normalized mutual information.

Estas medidas no se usan para construir los clusters, sino para evaluar su correspondencia con una clasificación externa.

Adjusted Rand Index

El Rand Index compara pares de observaciones.

El Adjusted Rand Index corrige por acuerdo esperado al azar:

$$ARI = \frac{RI - E(RI)}{\max(RI) - E(RI)}$$

Interpretación:

$ARI = 1 \Rightarrow$ acuerdo perfecto

$ARI \approx 0 \Rightarrow$ acuerdo similar al azar

$ARI < 0 \Rightarrow$ acuerdo peor que el azar

Además de k-means y clustering jerárquico, existen otros métodos relevantes:

- **DBSCAN**: clustering basado en densidad.
- **Gaussian Mixture Models**: clustering probabilístico.
- **Spectral clustering**: clustering basado en grafos.
- **PAM**: partición alrededor de medoides.
- **Clustering sobre componentes principales**: útil en alta dimensión.

La elección depende del tipo de datos, la geometría esperada de los grupos y el objetivo del análisis.

DBSCAN agrupa observaciones según densidad local.

Usa dos parámetros:

ε = radio de vecindad

$minPts$ = mínimo número de puntos

Ventajas:

- no requiere fijar K ;
- puede detectar clusters de forma irregular;
- identifica observaciones como ruido.

Desventajas:

- sensible a la elección de ε ;
- puede fallar con densidades muy distintas.

Clústeres por Densidad: El Enfoque DBSCAN

A diferencia de otros métodos, **DBSCAN** no busca formas geométricas fijas. Encuentra grupos basándose en la **concentración o densidad** de los puntos, ignorando el ruido.

La Analogía del Centro Comercial (Ej: Plaza Lagos)

Imagina que quieres identificar las zonas de mayor aglomeración de personas un sábado por la tarde:

- **Puntos Core (Núcleo):** Mesas de restaurantes llenas. Locales donde hay un “grupo compacto” de al menos N personas muy cerca unas de otras.
- **Puntos Borde:** Personas que caminan solas por los pasillos, pero están justo al lado de un restaurante lleno. Pertenecen al grupo por proximidad.
- **Ruido (Outliers):** Un guardia de seguridad parado solo en una esquina remota del parqueadero. Está aislado y el algoritmo lo descarta.

Ventajas No Técnicas

- **Formas libres:** Encuentra grupos alargados, en curvas o anillos (no solo círculos).
- **Filtra la basura:** Detecta automáticamente los datos aislados (ruido).

La Única Condición

Requiere que le digas dos cosas en su idioma:

- ¿Qué tan cerca es “cerca”? (Radio).
- ¿Cuánta gente hace un grupo? (Mínimo de puntos).

Gaussian Mixture Models

Los modelos de mezcla gaussiana suponen que los datos provienen de una mezcla de distribuciones normales:

$$f(x) = \sum_{k=1}^K \pi_k \phi(x|\mu_k, \Sigma_k)$$

donde:

π_k = peso del componente k

μ_k = media del componente k

Σ_k = matriz de covarianzas

A diferencia de k-means, producen asignaciones probabilísticas.

$$P(z_i = k|x_i)$$

Clustering y reducción de dimensión

En alta dimensión, las distancias pueden volverse menos informativas.

Una estrategia común es:

$$X \rightarrow \text{PCA} \rightarrow \text{scores principales} \rightarrow \text{clustering}$$

Ventajas:

- reduce ruido;
- facilita visualización;
- disminuye dimensionalidad;
- puede mejorar la estabilidad de los clusters.

Precaución: al reducir dimensión también se puede perder información relevante.

Errores comunes en clustering

Errores frecuentes:

- aplicar clustering sin estandarizar variables cuando las escalas son distintas;
- interpretar clusters sin validar su estabilidad;
- asumir que todo algoritmo produce grupos reales;
- elegir K solo por conveniencia;
- usar distancia euclidiana con datos categóricos;
- comparar soluciones sin considerar la métrica usada;
- ignorar valores atípicos.

El clustering siempre produce una partición; eso no garantiza que la estructura sea sustantivamente significativa.

Cómo reportar un análisis de clustering

En un informe académico se debe especificar:

- variables utilizadas;
- tratamiento de datos faltantes;
- estandarización aplicada;
- métrica de distancia o similaridad;
- algoritmo utilizado;
- criterio de enlace, si corresponde;
- método para elegir el número de clusters;
- métricas de validación;
- interpretación sustantiva de los grupos.

Ejemplo de redacción metodológica

Se aplicó un análisis de conglomerados con el objetivo de identificar patrones multivariantes entre las observaciones.

Las variables cuantitativas fueron previamente estandarizadas mediante puntuaciones z , con el fin de evitar que las diferencias de escala dominaran el cálculo de disimilitudes.

Se calcularon distancias euclidianas y se implementaron métodos jerárquicos aglomerativos bajo criterios de enlace Ward, average y complete.

La selección del número de conglomerados se basó en la inspección del dendrograma, el método del codo y el índice silhouette.

Concepto	Idea principal
Cluster	Grupo de observaciones similares
Distancia	Separación entre observaciones
Similaridad	Grado de parecido
Centroide	Media del cluster
Medoide	Observación real representativa
K-means	Minimiza variación interna
Jerárquico	Construye un dendrograma
Ward	Minimiza incremento de varianza
Average	Promedio de distancias
Silhouette	Cohesión y separación

El clustering no es solamente aplicar un algoritmo.

Es una secuencia de decisiones:

variables → escala → distancia → algoritmo → número de clusters → validación → interpretación

Una buena solución de clustering debe ser:

- estadísticamente coherente;
- estable;
- interpretable;
- consistente con el conocimiento del problema.

Bibliografía I

-  James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). *An Introduction to Statistical Learning: With Applications in R*. Second Edition. Springer.
-  Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Second Edition. Springer.
-  Kaufman, L., & Rousseeuw, P. J. (1990). *Finding Groups in Data: An Introduction to Cluster Analysis*. Wiley.
-  Everitt, B. S., Landau, S., Leese, M., & Stahl, D. (2011). *Cluster Analysis*. Fifth Edition. Wiley.
-  Mardia, K. V., Kent, J. T., & Bibby, J. M. (1979). *Multivariate Analysis*. Academic Press.
-  Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236–244.

-  Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.
-  Caliński, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. *Communications in Statistics*, 3(1), 1–27.
-  Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2), 224–227.