

Modelos de clasificación

Estadística para Datos Multivariantes

Francisco Moreira Villegas

11 de junio de 2026

Unidad 3: Modelos de clasificación

- ▶ En esta unidad estudiaremos métodos para asignar observaciones a grupos o categorías.
- ▶ El interés principal será modelar una variable respuesta categórica o identificar estructuras de agrupamiento.
- ▶ Se combinará interpretación estadística, evaluación del desempeño y aplicación en R.

Datos $\longrightarrow$ **Modelo** $\longrightarrow$ **Clase / Grupo**

¿Qué es un problema de clasificación?

- ▶ La variable de interés pertenece a un conjunto finito de categorías.
- ▶ El objetivo es construir una regla que permita clasificar nuevas observaciones.
- ▶ Ejemplos:
 - ▶ Cliente con riesgo bajo o alto.
 - ▶ Estudiante aprueba o reprueba.
 - ▶ Paciente sano o enfermo.
 - ▶ Jugador con bajo, medio o alto rendimiento.

Clasificar implica aprender una frontera de decisión a partir de los datos.

Clasificación supervisada y no supervisada

Supervisada

- ▶ La clase es conocida.
- ▶ Se entrena un modelo.
- ▶ Se evalúa capacidad predictiva.

Ejemplos:

- ▶ Regresión logística
- ▶ Análisis discriminante

No supervisada

- ▶ La clase no es conocida.
- ▶ Se buscan grupos naturales.
- ▶ Se interpreta estructura interna.

Ejemplo:

- ▶ Análisis de clúster

Métodos principales de la unidad

- ▶ **Regresión logística binaria:** modela la probabilidad de pertenecer a una categoría.
- ▶ **Análisis discriminante:** construye funciones para separar grupos conocidos.
- ▶ **Análisis de clúster:** identifica grupos de observaciones similares sin etiquetas previas.

La elección del método depende de si conocemos o no las clases de antemano.

Regresión logística binaria

- ▶ La regresión logística binaria se utiliza cuando la variable respuesta tiene dos categorías.
- ▶ El objetivo es modelar la probabilidad de ocurrencia de un evento.
- ▶ No se predice directamente una clase, sino una probabilidad.

$$Y = \begin{cases} 1, & \text{ocurre el evento} \\ 0, & \text{no ocurre el evento} \end{cases}$$

Clasificar implica transformar una probabilidad en una decisión.

Ejemplos de variables binarias

Evento de interés

- ▶ Cliente compra
- ▶ Estudiante aprueba
- ▶ Paciente presenta enfermedad
- ▶ Equipo gana

Codificación

- ▶ Compra = 1
- ▶ Aprueba = 1
- ▶ Enfermedad = 1
- ▶ Victoria = 1

La categoría codificada como 1 define qué probabilidad estamos modelando.

¿Por qué no usar regresión lineal?

- ▶ Una regresión lineal puede producir predicciones menores que 0 o mayores que 1.
- ▶ Para una variable binaria, necesitamos una función que produzca valores entre 0 y 1.
- ▶ Además, el efecto de los predictores sobre la probabilidad no suele ser constante.

$$0 \leq P(Y = 1 \mid X) \leq 1$$

La regresión logística modela probabilidades válidas.

La probabilidad como objeto de modelado

- Sea $p(X)$ la probabilidad condicional del evento:

$$p(X) = P(Y = 1 \mid X)$$

- La regresión logística relaciona esta probabilidad con un conjunto de predictores:

$$X_1, X_2, \dots, X_p$$

- El modelo permite estimar cómo cambian las probabilidades según las características observadas.

El centro del análisis no es Y , sino $P(Y = 1 \mid X)$.

Función logística

- ▶ La función logística transforma cualquier valor real en una probabilidad.

$$p(X) = \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p}}$$

- ▶ El resultado siempre está entre 0 y 1.
- ▶ La relación entre predictores y probabilidad tiene forma no lineal.


El modelo es lineal en los parámetros, pero no en la probabilidad.

Función logística

- ▶ Transforma cualquier valor real en una probabilidad.
- ▶ Sus valores siempre están entre 0 y 1.
- ▶ Es la base de la regresión logística binaria.

$$p(z) = \frac{1}{1 + e^{-z}}$$

$$z = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$



Odds y log-odds

- Los **odds** comparan la probabilidad de ocurrencia contra la probabilidad de no ocurrencia.

$$\text{odds} = \frac{p(X)}{1 - p(X)}$$

- La regresión logística modela el logaritmo de los odds:

$$\log \left(\frac{p(X)}{1 - p(X)} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

El modelo es lineal en la escala log-odds.

Odds: razón de posibilidades

- ▶ En regresión logística, los **odds** comparan la probabilidad de ocurrencia con la probabilidad de no ocurrencia.

$$\text{odds} = \frac{p}{1 - p}$$

- ▶ Si $p = 0,80$, entonces:

$$\text{odds} = \frac{0,80}{0,20} = 4$$

La razón de posibilidades de ocurrencia es 4 a 1.

Ejemplo motivador

- ▶ Queremos estimar la probabilidad de que una persona desarrolle una enfermedad.
- ▶ La variable respuesta es binaria:

$$Y = \begin{cases} 1, & \text{desarrolla enfermedad} \\ 0, & \text{no desarrolla enfermedad} \end{cases}$$

- ▶ Las variables explicativas pueden ser:

Edad, Tabaquismo, Presión sistólica

El objetivo no es predecir un número continuo, sino una probabilidad.

Modelo logístico del ejemplo

- Supongamos el siguiente modelo:

$$p(X) = P(Y = 1 \mid X)$$

$$p(X) = \frac{1}{1 + e^{-(-6,614 + 0,075X_1 + 0,312X_2 + 0,018X_3)}}$$

- X_1 : edad.
- X_2 : fumador, donde 1 = sí y 0 = no.
- X_3 : presión sistólica.

La función logística asegura que la predicción esté entre 0 y 1.

Cálculo para un perfil específico

- Consideremos una persona con el siguiente perfil:

$$X_1 = 58, \quad X_2 = 1, \quad X_3 = 150$$

- Es decir:
 - 58 años.
 - Fumador.
 - Presión sistólica de 150.

$$p(X) = \frac{1}{1 + e^{-(-6,614 + 0,075(58) + 0,312(1) + 0,018(150))}}$$

$$\hat{p}(X) \approx 0,68$$

Interpretación de la probabilidad

- ▶ Para el perfil analizado, el modelo estima:

$$\hat{p}(X) = 0,68$$

- ▶ Esto significa que la probabilidad estimada de desarrollar la enfermedad es del 68 %.
- ▶ En términos aplicados:

De cada 100 personas con ese perfil,
aproximadamente 68 desarrollarían la enfermedad.

- ▶ Esta interpretación es probabilística, no determinística.

De probabilidad a clasificación

- El modelo entrega una probabilidad estimada:

$$\hat{p}(X) = 0,68$$

- Para clasificar, se define un punto de corte c .

$$\hat{Y} = \begin{cases} 1, & \text{si } \hat{p}(X) \geq c \\ 0, & \text{si } \hat{p}(X) < c \end{cases}$$

- Si usamos $c = 0,50$, entonces:

$$0,68 \geq 0,50 \quad \Rightarrow \quad \hat{Y} = 1$$

El individuo sería clasificado como de alto riesgo.

Odds: razón de posibilidades

- Los **odds** comparan la probabilidad del evento con la probabilidad del no evento.

$$\text{odds} = \frac{p}{1 - p}$$

- Para el ejemplo:

$$\text{odds} = \frac{0,68}{1 - 0,68} = \frac{0,68}{0,32} = 2,125$$

La razón de posibilidades de desarrollar la enfermedad es aproximadamente 2.13 a 1.

Interpretación del tabaquismo

- ▶ En el modelo, el coeficiente asociado a fumar es:

$$\beta_2 = 0,312$$

- ▶ Su odds ratio se obtiene como:

$$OR = e^{\beta_2} = e^{0,312} \approx 1,36$$

Manteniendo constantes edad y presión sistólica, los fumadores tienen odds 1.36 veces mayores que los no fumadores.

- ▶ En otras palabras, el tabaquismo incrementa la razón de posibilidades del evento.

Interpretación de la Presión sistólica

- ▶ En el modelo, el coeficiente asociado a la presión sistólica es:

$$\beta_3 = 0,018$$

- ▶ Su odds ratio se obtiene como:

$$OR = e^{\beta_3} = e^{0,018} \approx 1,018$$

Por cada unidad adicional de presión sistólica, los odds de desarrollar la enfermedad se multiplican por 1.018.

- ▶ Equivale a un aumento aproximado del 1.8 % en la razón de posibilidades.
- ▶ No significa que la probabilidad aumente 1.8 puntos porcentuales.

Interpretación general de los coeficientes

- ▶ En regresión logística, los coeficientes se interpretan en la escala logit:

$$\log \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 X_1 + \cdots + \beta_p X_p$$

- ▶ Para una variable continua:

$$e^{\beta_j}$$

representa el cambio multiplicativo en los odds cuando X_j aumenta una unidad.

- ▶ Para una variable binaria:

$$e^{\beta_j}$$

compara los odds entre la categoría 1 y la categoría 0.

Lectura estadística del ejemplo

- ▶ La probabilidad estimada permite cuantificar riesgo individual.
- ▶ El odds ratio permite interpretar el efecto relativo de una variable explicativa.
- ▶ La clasificación depende del punto de corte seleccionado.
- ▶ La calidad del modelo debe evaluarse con medidas de desempeño.

La regresión logística combina predicción,
clasificación e interpretación.

Ejemplo en R: regresión logística binaria

- ▶ Usaremos la base `mtcars`.
- ▶ La variable respuesta será el tipo de transmisión:

$$Y = \begin{cases} 1, & \text{transmisión manual} \\ 0, & \text{transmisión automática} \end{cases}$$

- ▶ Predictores:
 - ▶ `wt`: peso del auto.
 - ▶ `hp`: potencia del motor.

El objetivo es estimar $P(\text{manual} = 1 \mid wt, hp)$.

Ajuste del modelo en R

```
data(mtcars)

modelo_log <- glm(am ~ wt + hp,
                  data = mtcars,
                  family = binomial)

summary(modelo_log)
```

- ▶ family = binomial indica que la respuesta es binaria.
- ▶ El modelo se ajusta en escala logit.

Odds ratios en R

```
coef(modelo_log)
exp(coef(modelo_log))
```

- ▶ `coef(modelo_log)` entrega coeficientes en escala logit.
- ▶ `exp(coef(modelo_log))` entrega los odds ratios.

Los odds ratios permiten interpretar el efecto multiplicativo sobre la razón de posibilidades.

Predicción y clasificación

```
probabilidades <- predict(modelo_log,  
                           type = "response")  
  
pred_manual <- ifelse(probabilidades >= 0.50,  
                      1, 0)  
  
table(Real = mtcars$am,  
      Predicho = pred_manual)
```

- ▶ El modelo entrega probabilidades.
- ▶ El punto de corte convierte probabilidades en clases.

Matriz de confusión

- ▶ En clasificación binaria comparamos la clase real con la clase predicha por el modelo.

	Predicho: 0	Predicho: 1
Real: 0	VN	FP
Real: 1	FN	VP

- ▶ **VP**: verdadero positivo. El evento ocurre y el modelo predice evento.
- ▶ **VN**: verdadero negativo. El evento no ocurre y el modelo predice no evento.
- ▶ **FP**: falso positivo. El evento no ocurre, pero el modelo predice evento.
- ▶ **FN**: falso negativo. El evento ocurre, pero el modelo predice no evento.

Sensibilidad y especificidad

- ▶ En clasificación binaria, no basta con contar cuántas predicciones fueron correctas.
- ▶ Es necesario distinguir qué tan bien el modelo detecta los casos positivos y los negativos.

Sensibilidad

$$\frac{VP}{VP + FN}$$

Capacidad del modelo para identificar correctamente los casos positivos.

Especificidad

$$\frac{VN}{VN + FP}$$

Capacidad del modelo para identificar correctamente los casos negativos.

Un modelo puede ser bueno detectando positivos, pero débil descartando negativos, o viceversa.

Otro ejemplo en R

```
data(iris)

head(iris)
table(iris$Species)

X <- iris[, 1:4]
y <- iris$Species
```

- ▶ X: variables predictoras.
- ▶ y: clase observada.
- ▶ El objetivo será usar X para explicar o predecir y.

Separación entrenamiento/prueba

```
set.seed(123)

n <- nrow(iris)
id_train <- sample(1:n, size = 0.7*n)

train <- iris[id_train, ]
test  <- iris[-id_train, ]

table(train$Species)
table(test$Species)
```

Regresión logística multinomial

```
library(nnet)

modelo_log <- multinom(Species ~ Sepal.Length +
                        Sepal.Width +
                        Petal.Length +
                        Petal.Width,
                        data = train)

pred_log <- predict(modelo_log, newdata = test)

table(Real = test$Species,
      Predicho = pred_log)
```


Exactitud del modelo

```
matriz_confusion <- table(Real = test$Species,  
                          Predicho = pred_log)  
  
accuracy <- sum(diag(matriz_confusion)) /  
             sum(matriz_confusion)  
  
accuracy
```

La exactitud resume el porcentaje de observaciones correctamente clasificadas.

Análisis Discriminante Lineal

- ▶ El **Análisis Discriminante Lineal** se utiliza para clasificar observaciones en grupos conocidos.
- ▶ Las clases ya están observadas en los datos de entrenamiento.
- ▶ El objetivo es construir una regla que permita asignar nuevas observaciones a una clase.

$$Y \in \{1, 2, \dots, K\}$$

LDA es un método de clasificación supervisada.

Idea central de LDA

- ▶ LDA busca separar grupos usando combinaciones lineales de las variables predictoras.
- ▶ Cada observación se asigna al grupo con mayor evidencia estadística.
- ▶ La regla de clasificación se basa en:

$$P(Y = k \mid X = x)$$

**Nueva observación $\longrightarrow$ probabilidad por grupo
 $\longrightarrow$ clase asignada**

¿Qué modela LDA?

- ▶ LDA parte de una idea generativa:

$$f_k(x) = P(X = x \mid Y = k)$$

- ▶ Es decir, modela la distribución de los predictores dentro de cada grupo.
- ▶ Luego usa el teorema de Bayes para obtener:

$$P(Y = k \mid X = x)$$

Primero se describe cómo son los datos dentro de cada clase; luego se clasifica.

Regla de Bayes para clasificación

- ▶ La probabilidad posterior de pertenecer al grupo k es:

$$P(Y = k \mid X = x) = \frac{\pi_k f_k(x)}{\sum_{\ell=1}^K \pi_\ell f_\ell(x)}$$

- ▶ π_k : probabilidad previa del grupo k .
- ▶ $f_k(x)$: densidad de los predictores en el grupo k .
- ▶ K : número de grupos.

La observación se asigna al grupo con mayor probabilidad posterior.

Nuevo perfil observado

58 años, fumador, PAS = 150

Grupo 1
No enfermo

Grupo 2
Enfermo

¿Dónde encaja mejor?

Regla de Bayes: ejemplo simple

- Para una nueva persona, el modelo calcula:

Grupo	Probabilidad posterior
No enfermo	0.30
Enfermo	0.70

- Como la probabilidad de pertenecer al grupo **Enfermo** es mayor:

$$0,70 > 0,30$$

Clasificación: Enfermo

Cómo explicar la regla de Bayes

- ▶ La regla de Bayes combina dos fuentes de información:

1. Frecuencia del grupo

¿Qué tan común es cada grupo en la población?

Previo

2. Perfil observado

¿Qué tan compatible es el perfil con cada grupo?

Evidencia

Bayes actualiza lo que sabíamos antes usando la información del individuo.

Interpretación para clasificación

- ▶ Si el perfil de una persona se parece mucho al grupo de enfermos, aumenta su probabilidad posterior de estar enferma.
- ▶ Si el perfil se parece más al grupo de no enfermos, se clasifica como no enferma.
- ▶ El modelo no “adivina”: compara probabilidades entre grupos.

Clasificar es elegir el grupo más probable dado el perfil observado.

Supuestos principales de LDA

- ▶ Los predictores siguen una distribución normal multivariante dentro de cada grupo.
- ▶ Los grupos pueden tener medias diferentes.
- ▶ Todos los grupos comparten la misma matriz de covarianzas.

$$X \mid Y = k \sim N_p(\mu_k, \Sigma)$$

La igualdad de covarianzas genera fronteras de decisión lineales.

¿Por qué se llama “lineal”?

- ▶ Bajo los supuestos de LDA, la regla de clasificación produce fronteras lineales.
- ▶ Esto significa que la separación entre dos grupos puede representarse mediante una recta, plano o hiperplano.

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log(\pi_k)$$

La clase asignada es aquella con mayor función discriminante.

Función discriminante

- ▶ Para cada grupo se calcula una puntuación discriminante:

$$\delta_k(x)$$

- ▶ Luego se clasifica la observación en el grupo con mayor puntuación:

$$\hat{Y} = \arg \max_k \delta_k(x)$$

Mayor puntuación discriminante $\Rightarrow$ grupo asignado

LDA con dos grupos

- ▶ Cuando existen dos grupos, LDA construye una regla de separación entre ellos.
- ▶ La frontera de decisión es lineal.
- ▶ Una nueva observación se asigna al grupo más probable.

$$Y \in \{0, 1\}$$

En clasificación binaria, LDA puede compararse directamente con regresión logística.

LDA con varios grupos

- ▶ LDA también puede aplicarse cuando existen más de dos clases.
- ▶ Para cada grupo se estima una media:

$$\mu_1, \mu_2, \dots, \mu_K$$

- ▶ La matriz de covarianzas se estima de forma común para todos los grupos:

$$\Sigma$$

LDA compara simultáneamente todas las clases posibles.

LDA vs. regresión logística

Aspecto	Regresión logística	LDA
Tipo de modelo	Discriminativo	Generativo
Qué modela	$P(Y = 1 \mid X)$	$P(X \mid Y = k)$
Respuesta	Usualmente binaria o multinomial	Dos o más grupos
Supuestos sobre X	Menos restrictivos	Normalidad multivariante
Frontera	Lineal en el logit	Lineal por covarianza común

Ambos clasifican, pero parten de enfoques estadísticos diferentes.

¿Cuándo usar LDA?

- ▶ Cuando las clases están claramente definidas en los datos de entrenamiento.
- ▶ Cuando se desea una regla de clasificación interpretable.
- ▶ Cuando las variables predictoras son aproximadamente normales dentro de cada grupo.
- ▶ Cuando las matrices de covarianza de los grupos son razonablemente similares.

LDA es especialmente útil como método clásico, interpretable y eficiente de clasificación.

Limitaciones de LDA

- ▶ Puede funcionar mal si las fronteras reales entre grupos son no lineales.
- ▶ Es sensible a desviaciones fuertes de normalidad multivariante.
- ▶ La presencia de outliers puede afectar las medias y covarianzas estimadas.
- ▶ Si los grupos tienen covarianzas muy distintas, puede ser más adecuado usar QDA.

Como todo modelo, LDA requiere evaluar si sus supuestos son razonables para el problema.


Mensaje clave

- ▶ LDA es un método supervisado de clasificación.
- ▶ Modela la distribución de los predictores dentro de cada grupo.
- ▶ Usa probabilidades posteriores para asignar nuevas observaciones.
- ▶ Su supuesto de covarianza común produce fronteras lineales.

LDA clasifica comparando qué grupo hace más probable a la observación.

LDA: frontera de decisión

- ▶ LDA separa grupos usando una frontera lineal.
- ▶ Cada punto representa una observación.
- ▶ Una nueva observación se asigna al grupo más probable.



La línea divide el espacio en regiones de clasificación.

Análisis discriminante lineal

```
library(MASS)

modelo_lda <- lda(Species ~ Sepal.Length +
                  Sepal.Width +
                  Petal.Length +
                  Petal.Width,
                  data = train)

pred_lda <- predict(modelo_lda,
                    newdata = test)

table(Real = test$Species,
      Predicho = pred_lda$class)
```

Actividad aplicada: riesgo crediticio

- ▶ Objetivo: predecir si un cliente entra o no en **default**.
- ▶ Se compararán dos métodos de clasificación:
 - ▶ Regresión logística binaria.
 - ▶ Análisis Discriminante Lineal.
- ▶ Al final, compararemos sus matrices de confusión.

$$Y = \begin{cases} 1, & \text{default} = \text{Yes} \\ 0, & \text{default} = \text{No} \end{cases}$$

El problema central es clasificar clientes según su riesgo crediticio.

Base de datos

- ▶ Usaremos la base `Default` del paquete `ISLR2`.
- ▶ Variables principales:
 - ▶ `default`: indica si el cliente incumplió el pago.
 - ▶ `student`: indica si el cliente es estudiante.
 - ▶ `balance`: saldo promedio de tarjeta de crédito.
 - ▶ `income`: ingreso anual.

La respuesta es binaria, por eso es adecuada para clasificación.

Tareas de la actividad

1. Explorar la variable default.
2. Separar los datos en entrenamiento y prueba.
3. Ajustar una regresión logística binaria.
4. Ajustar un modelo LDA.
5. Comparar las matrices de confusión.

La comparación no será solo por exactitud, sino también por sensibilidad y especificidad.

Comparación de modelos

- ▶ Compararemos ambos modelos usando:

Modelo	Accuracy	Sensibilidad	Especificidad
Regresión logística			
LDA			

En riesgo crediticio, detectar correctamente los defaults suele ser más importante que maximizar solo la exactitud.

Preguntas de discusión

1. ¿Cuál modelo clasifica mejor en términos generales?
2. ¿Cuál modelo detecta mejor a los clientes que sí entran en default?
3. ¿Cuál modelo descarta mejor a los clientes que no entran en default?
4. ¿Qué error sería más costoso para una institución financiera?

La mejor matriz de confusión depende del objetivo del negocio.

Tipos de métodos de clustering

Clustering aglomerativo

- ▶ Parte de observaciones individuales.
- ▶ Fusiona grupos progresivamente.
- ▶ Construye una jerarquía de abajo hacia arriba.
- ▶ Se representa mediante un dendrograma.

Individuos → **Grupos**

Clustering divisivo o separativo

- ▶ Parte de un único grupo inicial.
- ▶ Divide los datos progresivamente.
- ▶ Construye una jerarquía de arriba hacia abajo.
- ▶ Busca particiones cada vez más específicas.

Grupo total → **Subgrupos**

Ambos enfoques buscan estructura en los datos, pero recorren caminos opuestos.

Familias de métodos de clustering

- ▶ **Métodos particionales:** dividen los datos en un número fijo de grupos.

Ejemplo: K-means

- ▶ **Métodos jerárquicos aglomerativos:** fusionan observaciones o grupos progresivamente.

n grupos $\longrightarrow$ 1 grupo

- ▶ **Métodos jerárquicos divisivos:** dividen progresivamente un grupo inicial.

1 grupo $\longrightarrow$ n grupos

K-means no construye una jerarquía; construye una partición directa de los datos.

Ejemplo en R: aglomerativo y separativo

```
X <- scale(iris[, 1:4])

# Aglomerativo
distancias <- dist(X)
hc_aglo <- hclust(distancias,
                  method = "ward.D2")

plot(hc_aglo,
     labels = FALSE,
     main = "Clustering aglomerativo")

# Separativo
library(cluster)
hc_sep <- diana(X)

plot(hc_sep,
     main = "Clustering separativo")
```

Análisis de clúster: preparación

```
X <- iris[, 1:4]  
  
X_scaled <- scale(X)  
  
head(X_scaled)
```

En clustering, escalar ayuda a evitar que una variable domine la distancia.

Clustering con K-means

```
set.seed(123)

km <- kmeans(X_scaled, centers = 3,
             nstart = 25)

km$centers
km$size
```

Comparación con grupos reales

```
table(Cluster = km$cluster,  
      Especie = iris$Species)
```

El clúster no usa las etiquetas reales; solo busca similitud entre observaciones.

Visualización de clústeres

```
plot(X_scaled[, 3], X_scaled[, 4],  
     col = km$cluster,  
     pch = 19,  
     xlab = "Petal.Length",  
     ylab = "Petal.Width")  
  
points(km$centers[, 3], km$centers[, 4],  
       col = 1:3, pch = 8, cex = 2)
```


Bibliografía base

- ▶ Hastie, Tibshirani y Friedman. *The Elements of Statistical Learning*.
- ▶ Izenman. *Modern Multivariate Statistical Techniques*.
- ▶ Rencher y Christensen. *Methods of Multivariate Analysis*.